



Data Preprocessing — সম্পূর্ণ বাংলা ব্যাখ্যা

◆ ১. Data Quality — ডেটার মান কেন গুরুত্বপূর্ণ?

বাস্তব জীবনের ডেটা সবসময় পরিষ্কার বা নিখুঁত থাকে না। এই ডেটাকে বলা হয় **"dirty data"** বা নোংরা ডেটা। এটি তিন ধরনের সমস্যায় ভুগতে পারে:

১. **Incomplete** (অসম্পূর্ণ): কিছু তথ্য মিসিং বা অনুপস্থিত থাকে।

- উদাহরণ: একজন কাস্টমারের **occupation** ফিল্ডে কোনো ডেটা নেই।
- কারণগুলো: ডেটা সংগ্রহের সময় যন্ত্র নষ্ট ছিল, তথ্যটি অপ্রাসঙ্গিক মনে হয়েছিল, বা ব্যক্তি তথ্য দিতে অস্বীকার করেছে।

২. **Noisy** (ত্রুটিপূর্ণ): ডেটায় ভুল বা অস্বাভাবিক মান থাকে।

- উদাহরণ: **Salary = -10** — বেতন নেগেটিভ হওয়া অসম্ভব।
- কারণ: ডেটা এন্ট্রিতে মানুষের ভুল, নেটওয়ার্ক এরর, বা অনুমানপ্রসূত ভুল।

৩. **Inconsistent** (অসংগতিপূর্ণ): একই তথ্য বিভিন্ন জায়গায় ভিন্নভাবে সংরক্ষিত।

- উদাহরণ: **Age = 42** কিন্তু **Birthday = 03/07/1997** — বয়স মিলছে না!
- অথবা রেটিং পদ্ধতি বদলে গেছে: আগে 1, 2, 3 এখন A, B, C।

◆ ২. Data Quality-র পরিমাপের মাত্রাসমূহ

ডেটার মান কতটা ভালো তা ৬টি দিক দিয়ে বিচার করা হয়:

মাত্রা	অর্থ
Accuracy	ডেটা সঠিক কিনা
Completeness	কোনো তথ্য বাদ গেছে কিনা
Consistency	বিভিন্ন জায়গায় ডেটা মিলছে কিনা

Timeliness	ডেটা আপডেট হয়েছে কিনা
Believability	ডেটা কতটা বিশ্বাসযোগ্য
Interpretability	ডেটা সহজে বোঝা যায় কিনা

◆ ৩. Data Preprocessing কেন জরুরি?

"No quality data, no quality mining results" — মানহীন ডেটা থেকে ভালো ফলাফল পাওয়া অসম্ভব।

- বেশিরভাগ মাইনিং অ্যালগরিদম অসম্পূর্ণ বা noisy ডেটা সামলাতে পারে, কিন্তু সব পারে না।
 - Inconsistent ডেটা সামলানো প্রায় কোনো অ্যালগরিদমের পক্ষেই সম্ভব নয়।
 - ডেটার আকার অনেক বড় হলে সরাসরি মাইনিং করা সময়সাপেক্ষ।
 - একটি **Data Mining** টাস্কের প্রায় ৭০% সময় ব্যয় হয় শুধু **Data Preprocessing**-এ!
-

◆ ৪. Data Preprocessing-এর প্রধান কাজগুলো (Major Tasks)

চারটি প্রধান কাজ:

➤ Data Cleaning (ডেটা পরিষ্কার করা)

মিসিং ভ্যালু পূরণ, নোইসি ডেটা মসৃণ করা, outlier সরানো, inconsistency ঠিক করা।

➤ Data Integration (ডেটা একত্রিত করা)

একাধিক ডেটাবেজ বা ফাইল থেকে ডেটা একটি সংগত ভাণ্ডারে আনা।

➤ Data Reduction (ডেটা কমানো)

ডেটার পরিমাণ কমিয়ে আনা, কিন্তু বিশ্লেষণের ফলাফল একই রাখা।

➤ Data Transformation (ডেটা রূপান্তর)

Normalization বা Aggregation করে ডেটাকে উপযুক্ত ফরম্যাটে আনা।

◆ ৫. Data Cleaning — বিস্তারিত

✓ Missing Data কীভাবে সামলাবো?

পদ্ধতি	ব্যাখ্যা
Tuple ignore	পুরো রেকর্ডটি বাদ দাও (যদি class label মিসিং থাকে)
Manual fill	হাতে পূরণ করো — কিন্তু বড় ডেটাসেটে অবাস্তব
Global constant	সব মিসিং ভ্যালুতে "unknown" বসিয়ে দাও
Attribute mean	সেই column-এর গড় মান বসাও
Class-wise mean	একই class-এর সব রেকর্ডের গড় বসাও (আরও বুদ্ধিমান পদ্ধতি)
Most probable value	Bayesian formula বা Decision Tree দিয়ে সম্ভাব্য মান বের করো

✓ Noisy Data কীভাবে সামলাবো?

১. Binning (বিনিং):

- ডেটা sort করো এবং সমান ভাগে ভাগ করো (bins বা buckets)
- তারপর bin-এর:
 - **Mean** (গড়) দিয়ে প্রতিটি মান replace করো, বা
 - **Median** (মধ্যমান) দিয়ে, বা
 - **Boundary** (bin-এর সীমা মান) দিয়ে।

২. Clustering (ক্লাস্টারিং):

- একই ধরনের মানগুলো গ্রুপ করো।
- যেসব মান কোনো গ্রুপে পড়ে না সেগুলো **outlier** — এদের সরিয়ে দাও।

৩. Regression (রিগ্রেশন):

- ডেটাকে একটি regression line-এ fit করো।
 - যেসব মান line থেকে অনেক দূরে সেগুলো outlier হিসেবে চিহ্নিত হয়।
-

✓ Inconsistent Data কীভাবে সামলাবো?

- কিছু ক্ষেত্রে বাইরের রেফারেন্স ব্যবহার করে ম্যানুয়ালি ঠিক করতে হয়।
 - **Knowledge engineering tools** ব্যবহার করে known constraints লক্ষ্যন ধরা যায়।
 - সাধারণত user-এর হস্তক্ষেপ ছাড়া inconsistency ঠিক করা সম্ভব নয়।
-

◆ ৬. Data Integration — ডেটা একত্রিত করা

একাধিক ডেটাসোর্স থেকে ডেটা একটি সংগত store-এ নিয়ে আসার প্রক্রিয়া।

চ্যালেঞ্জ ১ — **Schema Integration:**

- **Entity Identification Problem:** দুটি ডেটাবেজে `family_name` এবং `surname` আসলে একই জিনিস — কিন্তু নাম আলাদা।
- **Semantic Heterogeneity:** `175cm` vs `1.75m` — একই জিনিস, আলাদা unit।

চ্যালেঞ্জ ২ — **Redundancy** সামলানো:

- একই attribute বিভিন্ন ডেটাবেজে বিভিন্ন নামে থাকতে পারে।
 - কিছু attribute অন্য attribute থেকে বের করা যায় (derived), যেমন বার্ষিক আয় = মাসিক আয় $\times ১২$ ।
 - **Correlation Analysis** এবং **Covariance Analysis** দিয়ে redundant attribute ধরা যায়।
-

◆ ৭. Correlation Analysis

Nominal Data-র জন্য: Chi-Square (X^2) Test

- দুটি categorical variable-এর মধ্যে সম্পর্ক আছে কিনা বোঝায়।
- X^2 মান যত বড়, সম্পর্ক তত শক্তিশালী।
- গুরুত্বপূর্ণ: Correlation মানে Causality নয়! একটি শহরে হাসপাতাল বেশি মানে গাড়ি চুরিও বেশি — কারণ উভয়ই জনসংখ্যার উপর নির্ভর করে।

Numeric Data-র জন্য: Pearson Correlation Coefficient (r)

- $r > 0 \rightarrow$ Positive correlation (একটি বাড়লে অন্যটিও বাড়ে)
- $r = 0 \rightarrow$ Independent (কোনো সম্পর্ক নেই)
- $r < 0 \rightarrow$ Negative correlation (একটি বাড়লে অন্যটি কমে)
- r এর মান -1 থেকে $+1$ এর মধ্যে থাকে।

Covariance (কোভেরিয়েন্স):

- $Cov > 0 \rightarrow$ দুটি variable একসাথে বাড়ে
- $Cov < 0 \rightarrow$ একটি বাড়লে অন্যটি কমে
- $Cov = 0 \rightarrow$ সম্ভবত independent (কিন্তু সবসময় নয়)

উদাহরণ: দুটি স্টক A ও B এর মান: (2,5), (3,8), (5,10), (4,11), (6,14)। $Cov(A,B) = 4 > 0$, অর্থাৎ উভয় স্টক একসাথে ওঠানামা করে।

❖ ৮. Data Reduction — ডেটা হ্রাস করা

বড় ডেটাবেজ (টেরাবাইট পরিমাণ) সরাসরি বিশ্লেষণ করা অসম্ভব। তাই ডেটার আকার কমিয়ে আনা হয় কিন্তু ফলাফল একই থাকে।

➤ Dimensionality Reduction (মাত্রা হ্রাস)

Curse of Dimensionality (মাত্রার অভিশাপ):

- features বা column বাড়তে থাকলে ডেটা ক্রমশ বিরল হয়ে পড়ে।
- দূরত্ব ও ঘনত্ব পরিমাপ করা কঠিন হয় — clustering বা outlier detection কার্যকর থাকে না।

সমাধান:

- **Attribute Subset Selection:** অপ্রয়োজনীয় বা redundant column বাদ দাও।
 - Redundant: `purchase_price` এবং `sales_tax` প্রায় একই তথ্য বহন করে।
 - Irrelevant: `student_ID` দিয়ে GPA predict করা যায় না।
-

➤ Heuristic Attribute Selection (বৈশিষ্ট্য নির্বাচনের পদ্ধতি)

পদ্ধতি	ব্যাখ্যা
Best step-wise selection	সেরা একটি বেছে নাও, তারপর সেটির সাথে সবচেয়ে ভালো মিলের আরেকটি যোগ করো
Step-wise elimination	সবচেয়ে খারাপটি বারবার বাদ দাও
Combined	সেরাটি যোগ করো, একই সাথে সবচেয়ে খারাপটি বাদ দাও

Branch & Bound attribute বাদ দাও এবং backtrack করো

Decision Tree Decision tree তৈরি করো, যেসব attribute tree-তে নেই সেগুলো বাদ দাও

➤ Wavelet Transform (ওয়েভলেট রূপান্তর)

- ডেটাকে বিভিন্ন resolution level-এ উপস্থাপন করে।
 - ছবি compression-এ ব্যবহার হয়।
 - শুধু সবচেয়ে শক্তিশালী wavelet coefficient সংরক্ষণ করা হয়, বাকিগুলো ০ করে দেওয়া হয়।
 - উদাহরণ: $S = [2, 2, 0, 2, 3, 5, 4, 4] \rightarrow$ compressed রূপে $S^* = [23/4, -11/4, 1/2, 0, 0, -1, -1, 0]$
-

➤ Principal Component Analysis — PCA (প্রধান উপাদান বিশ্লেষণ)

- উচ্চমাত্রার ডেটাকে কম মাত্রায় উপস্থাপন করে কিন্তু সর্বাধিক variance ধরে রাখে।
 - উদাহরণ: ২D ডেটাকে ১D-তে নিয়ে আসা — এমনভাবে যেন ডেটার পার্থক্য সর্বোচ্চ সংরক্ষিত থাকে।
-

➤ Numerosity Reduction (সংখ্যা হ্রাস)

Parametric (মডেল-ভিত্তিক):

- ডেটা একটি model-এ fit করো (যেমন regression), শুধু model parameters সংরক্ষণ করো।

Non-Parametric:

Histogram (হিস্টোগ্রাম):

- ডেটাকে bucket-এ ভাগ করো এবং প্রতিটি bucket-এর গড় সংরক্ষণ করো।
- Equal-width: সব bucket-এর range সমান।
- Equal-frequency: সব bucket-এ সমান সংখ্যক ডেটা পয়েন্ট।

Clustering (ক্লাস্টারিং):

- একই ধরনের object-কে cluster-এ রাখো।
- Cluster মানের দ্বারা পুরো ক্লাস্টার represent করা যায়।
- Quality মাপা হয়: diameter (সর্বোচ্চ দূরত্ব) এবং centroid distance (centroid থেকে গড় দূরত্ব) দিয়ে।

Sampling (স্যাম্পলিং):

- পুরো ডেটা থেকে একটি representative ছোট নমুনা নাও।

Sampling ধরন	ব্যাখ্যা
Simple Random (SRSWR)	প্রতিটি item বেছে নেওয়ার সমান সম্ভাবনা, একটি নেওয়ার পরও ফিরিয়ে রাখা হয়
Simple Random (SRSWOR)	একবার নেওয়া হলে সেটি আর population-এ থাকে না
Cluster Sampling	data-কে M cluster-এ ভাগ করো, তারপর কিছু cluster বেছে নাও
Stratified Sampling	ডেটাকে partition করো, প্রতিটি partition থেকে proportional sample নাও। Skewed ডেটার জন্য আদর্শ

Data Cube Aggregation:

- ডেটাকে বিভিন্ন level-এ aggregate করো (যেমন daily → monthly → yearly)।
- Task যতটুকু দরকার ততটুকু granularity ব্যবহার করো।

Data Compression:

- String compression: সাধারণত lossless।
- Audio/Video: সাধারণত lossy (কিছু তথ্য হারিয়ে যায়)।

◆ ১. Data Transformation — ডেটা রূপান্তর

ডেটাকে নতুন রূপে রূপান্তর করার পদ্ধতি:

✓ Normalization (নরমালাইজেশন)

ডেটাকে একটি নির্দিষ্ট সীমার মধ্যে নিয়ে আসা।

১. **Min-Max Normalization:**
$$v' = \frac{v - \min_A}{\max_A - \min_A} \times (\text{new_max} - \text{new_min}) + \text{new_min}$$

উদাহরণ: আয় \$12,000–\$98,000 → [0, 1] range-এ। \$73,000 → প্রায় 0.716

২. **Z-Score Normalization:**
$$v' = \frac{v - \mu}{\sigma}$$

μ = গড়, σ = standard deviation। উদাহরণ: $\mu = 54,000$, $\sigma = 16,000 \rightarrow \$73,000 \rightarrow (73000-54000)/16000 = 1.1875$

৩. Decimal Scaling:

- দশমিকের স্থান সরিয়ে মান ছোট করা। $|v'| < 1$ হওয়া পর্যন্ত ভাগ করা হয়।

✓ Discretization (বিচ্ছিন্নীকরণ)

Continuous (অবিরাম) ডেটাকে interval-এ ভাগ করা।

- উদাহরণ: বয়স $\rightarrow 0-18, 18-35, 35-60, 60+$

পদ্ধতিগুলো:

পদ্ধতি	ধরন
Binning	Unsupervised, top-down
Histogram Analysis	Unsupervised, top-down
Clustering	Unsupervised
Decision Tree	Supervised (class label ব্যবহার করে)
Chi-merge (X^2)	Supervised, bottom-up merge

Chi-Merge: একই class distribution-এর পার্শ্ববর্তী interval-গুলো merge করা হয়, যতক্ষণ না একটি predefined condition পূরণ হয়।

◆ ১০. Concept Hierarchy Generation (ধারণা শ্রেণিবিন্যাস তৈরি)

- নিম্ন-স্তরের ধারণাকে উচ্চ-স্তরের ধারণায় উন্নীত করা।
- উদাহরণ: **street < city < state < country**
- ডেটা ওয়্যারহাউসে drill-down (বিস্তারিত দেখা) ও roll-up (সারসংক্ষেপ দেখা)-র জন্য ব্যবহার হয়।

Automatic generation:

- যে attribute-এ সবচেয়ে বেশি distinct মান — সেটি hierarchy-র সর্বনিম্ন স্তরে থাকে।
 - উদাহরণ: street (674,339 distinct মান) → city (3,567) → province (365) → country (15)
-

◆ সারসংক্ষেপ (Summary)

বিষয়	মূল পয়েন্ট
Data Quality	Accuracy, Completeness, Consistency, Timeliness, Believability, Interpretability
Data Cleaning	Missing value, Noisy data, Outliers, Inconsistencies
Data Integration	Entity identification, Redundancy removal, Inconsistency detection
Data Reduction	Dimensionality reduction, Numerosity reduction, Data compression
Data Transformation	Normalization, Discretization, Concept hierarchy

💡 মনে রাখো: Data Mining-এর মোট কাজের ৭০% সময় শুধু Data Preprocessing-এই যায়। তাই এটি সবচেয়ে গুরুত্বপূর্ণ ধাপ। ভালো preprocessing ছাড়া ভালো mining result পাওয়া সম্ভব নয়।