

Data Visualization and Graphical Representation of Data

- Data Visualization is the process of representing data using graphical elements such as charts, graphs, and plots to make the data easier to understand and analyze.
- Humans understand pictures much faster than numbers.
- It transforms **raw data** → **visual representation** so that humans can quickly detect
 - Patterns
 - Trends
 - Relationships
 - outliers

১. Data Visualization কী?

Data Visualization হলো raw data-কে charts, graphs, plots ইত্যাদি graphical elements দিয়ে represent করার process। মূল উদ্দেশ্য: data সহজে বোঝা, analyze করা এবং decision নেওয়া।

মানুষের brain সংখ্যার চেয়ে ছবি অনেক দ্রুত বোঝে। Visualization raw data → visual form-এ convert করে যাতে আমরা তাড়াতাড়ি **patterns, trends, relationships, outliers** খুঁজে পাই।

উদাহরণ: ধরো তুমি ১০০০ জন ছাত্রের exam marks-এর list পেয়েছ। শুধু সংখ্যা দেখে কিছু বোঝা যায় না। কিন্তু একটা histogram বানালে তুমি এক নজরে দেখতে পাবে কতজন ৮০+ পেয়েছে, কোন range-এ সবচেয়ে বেশি ছাত্র আছে — এটাই visualization-এর পাওয়ার।

- Gain insight into an information space by mapping data onto graphical primitives
- Provide qualitative overview of large data sets
- Search for patterns, trends, structure, irregularities, relationships among data
- Help find interesting regions and suitable parameters for further quantitative analysis
- Provide a visual proof of computer representations derived

২. Why Data Visualization?

১. ডেটাকে গ্রাফিক্সে রূপান্তর করা (Mapping data onto graphical primitives)

অনেক সময় শুধু সংখ্যা দেখে কিছু বোঝা কঠিন হয়। ডাটা ভিজ্যুয়ালাইজেশনের মাধ্যমে আমরা ডেটাকে বিন্দু (**dots**), রেখা (**lines**) বা রঙে রূপান্তর করি। এতে পুরো "ইনফরমেশন স্পেস" বা তথ্যের জগৎটা আমাদের চোখের সামনে পরিষ্কার হয়ে ওঠে।

২. বড় ডাটা সেটের দ্রুত ধারণা পাওয়া (Provide qualitative overview)

মনে করো তোমার কাছে লাখ লাখ মানুষের তথ্য আছে। সেগুলো এক এক করে পড়া অসম্ভব। কিন্তু একটা গ্রাফ বা ম্যাপ দেখলে তুমি এক পলকেই বুঝতে পারবে কোথায় কী ঘটছে। এটি বড় বড় ডাটার একটি গুণগত সারসংক্ষেপ দেয়।

৩. প্যাটার্ন এবং সম্পর্ক খুঁজে বের করা (Search for patterns, trends, structure)

ভিজ্যুয়ালাইজেশনের মাধ্যমে আমরা সহজেই বুঝতে পারি:

- **Trends:** কোনো কিছু কি সময়ের সাথে বাড়ছে না কমছে?
- **Patterns:** কোনো বিশেষ ঘটনা কি বারবার ঘটছে?
- **Irregularities:** কোনো ডাটা কি অন্যগুলোর চেয়ে একদম আলাদা (Outliers)?
- **Relationships:** একটার সাথে কি অন্যটার কোনো সম্পর্ক আছে?

৪. পরবর্তী বিশ্লেষণের পথ তৈরি করা (Help find interesting regions)

গভীর গাণিতিক বা কোয়ান্টিটেটিভ অ্যানালাইসিস শুরু করার আগে ভিজ্যুয়ালাইজেশন আমাদের সাহায্য করে কোন অংশ নিয়ে কাজ করা উচিত তা ঠিক করতে। এটি একটি গাইড হিসেবে কাজ করে যা বলে দেয়—"এই অংশটি ইন্টারেস্টিং, এখানে আরও গবেষণা করা দরকার।"

৫. প্রমাণের ভিত্তি হিসেবে কাজ করা (Provide a visual proof)

কম্পিউটার যখন কোনো জটিল হিসাব-নিকাশ বা প্রেডিকশন দেয়, সেটা সাধারণ মানুষের কাছে বিশ্বাসযোগ্য করার জন্য ভিজ্যুয়াল প্রুফ বা দৃশ্যমান প্রমাণ দরকার হয়। ভিজ্যুয়ালাইজেশন সেই গাণিতিক ফলাফলকে চোখের সামনে বাস্তব রূপ দেয়।

সহজ কথায়: ডাটা ভিজ্যুয়ালাইজেশন আমাদের "দেখতে" সাহায্য করে যা শুধু সংখ্যা দিয়ে "পড়া" সম্ভব নয়। এটি জটিল বিষয়কে সহজ করে এবং সঠিক সিদ্ধান্ত নিতে সাহায্য করে।

Basic Statistical Descriptions of Data

- Central Tendency
- Dispersion of Data
- Graphic Displays

৩. Basic Statistical Descriptions of Data

যেকোনো data-কে বোঝার জন্য তিনটা মূল জিনিস লাগে:

- **Central Tendency** (কেন্দ্রীয় প্রবণতা): Mean, Median, Mode
- **Dispersion of Data** (বিস্তার): কতটা ছড়ানো আছে
- **Graphic Displays:** visual করে দেখানো

Central Tendency:

- **Mean (গড়):** সব value যোগ করে সংখ্যা দিয়ে ভাগ। সবচেয়ে common কিন্তু outlier-এ sensitive।

Formula:

$$\bar{x} = \frac{\sum x}{n}$$

- $\bar{x}$: Sample mean
- $\sum x$: Sum of all data points
- n : Total number of data points

2. Median (মধ্যমা)

The Median is the middle value when a dataset is ordered from smallest to largest. The formula depends on whether the total number of observations (n) is odd or even.

Case A: If n is Odd (বিজোড়)

The median is the exact middle position.

$$\text{Median} = \left(\frac{n+1}{2} \right)^{\text{th}} \text{ term}$$

Case B: If n is Even (জোড়)

The median is the average of the two middle terms.

$$\text{Median} = \frac{\left(\frac{n}{2} \right)^{\text{th}} \text{ term} + \left(\frac{n}{2} + 1 \right)^{\text{th}} \text{ term}}{2}$$

- **Mode:** সবচেয়ে বেশি যে value আসে।

উদাহরণ: ছাত্রদের marks: ৭০, ৭৫, ৮০, ৯৫, ১০০। Mean = ৮৪, Median = ৮০, Mode = নেই। যদি একজন ২০০ পায় তাহলে mean বেড়ে যাবে কিন্তু median একই থাকবে।

- Quartiles, outliers and boxplots
 - Quantile: data points that split the data distribution into equal-size consecutive sets.
 - **Quartiles**: Q_1 (25th percentile), Q_3 (75th percentile)
 - **Inter-quartile range**: $IQR = Q_3 - Q_1$
 - **Five number summary**: min, Q_1 , median, Q_3 , max
 - Boxplot: ends of the box are the quartiles; median is marked; add whiskers, and plot outliers individually
 - **Outlier**: usually, a value higher/lower than $1.5 \times IQR$

8. Measuring the Dispersion of Data

Quartiles, Outliers & Boxplot:

- **Quantile:** data-কে equal parts-এ ভাগ করে।
- **Q₁ (25th percentile), Q₃ (75th percentile)**
- **IQR = Q₃ - Q₁**
- **Five-number summary:** Min, Q₁, Median, Q₃, Max
- **Outlier:** সাধারণত $1.5 \times \text{IQR}$ -এর বাইরে।

Boxplot: Box-এর দুই প্রান্ত Q₁ ও Q₃, মাঝে median লাইন, whiskers min-max পর্যন্ত, outliers আলাদা point হিসেবে দেখানো হয়। **Min, Max is not visible in box plot. Only lower bound and upper bound are visible in Box Plot.**

- Variance and standard deviation (*sample: s, population: σ*)
 - **Variance:** (algebraic, scalable computation)
 - **Standard deviation s (or σ)** is the square root of variance s^2 (or σ^2)

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \left[\sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2 \right] \quad \sigma^2 = \frac{1}{N} \sum_{i=1}^n (x_i - \mu)^2 = \frac{1}{N} \sum_{i=1}^n x_i^2 - \mu^2$$

Variance & Standard Deviation:

Sample variance (s^2):

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \left[\sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2 \right]$$

Population variance (σ^2):



$$\sigma^2 = \frac{1}{N} \sum_{i=1}^n (x_i - \mu)^2 = \frac{1}{N} \sum_{i=1}^n x_i^2 - \mu^2$$

Standard deviation হলো variance-এর square root। এটা data কতটা mean-এর কাছাকাছি ছড়ানো আছে তা দেখায়।

উদাহরণ: দুটো class-এর marks একই mean কিন্তু এক class-এ সবাই ৮০-৮৫, আরেক class-এ ৪০ থেকে ১২০ — variance দ্বিতীয়টায় অনেক বেশি।


Boxplot Analysis

- **Five-number summary** of a distribution
 - Minimum, Q1, Median, Q3, Maximum
- **Boxplot**
 - Data is represented with a box
 - The ends of the box are at the first and third quartiles, i.e., the height of the box is IQR
 - The median is marked by a line within the box
 - Whiskers: two lines outside the box extended to Minimum and Maximum
 - Outliers: points beyond a specified outlier threshold, plotted individually



৫. Boxplot Analysis


Five-number summary দিয়ে data-এর distribution এক নজরে দেখা যায়। Box-এর height = IQR। Whiskers min-max পর্যন্ত। Outliers আলাদা দেখানো হয়। এটা খুব useful কারণ skewness বোঝা যায়।



© Byjus.co

বিষয়	৫-নাম্বার সামারি	বক্স প্লট (Whiskers)
ফোকাস	ডেটার একদম শুরু আর শেষ কোথায়।	ডেটার "স্বাভাবিক" সীমানা কোথায়।

আউটলায়ার	একে আলাদা করে চেনা যায় না, এটি Max বা Min এর ভেতরেই থাকে।	একে সীমানার (Bound) বাইরে আলাদা বিন্দু দিয়ে চিহ্নিত করা হয়।
-----------	--	---



Graphic Displays

- **Boxplot:** graphic display of five-number summary
- **Histogram:** x-axis are values, y-axis represents frequencies
- **Quantile plot:** each value x_i is paired with f_i indicating that approximately 100 f_i % of data are $\leq x_i$
- **Quantile-quantile (q-q) plot:** graphs the quantiles of one univariate distribution against the corresponding quantiles of another
- **Scatter plot:** each pair of values is a pair of coordinates and plotted as points in the plane

S. Graphic Displays

Graphic Displays হলো data-কে visual form-এ দেখানোর বিভিন্ন techniques। এর মধ্যে মূলগুলো:

- **Boxplot:** five-number summary (Min, Q_1 , Median, Q_3 , Max) দেখায়।
- **Histogram:** continuous data-এর frequency distribution।
- **Quantile plot:** প্রত্যেক data point-এর percentile সাথে plot করে।
- **Quantile-Quantile (Q-Q) plot:** দুটো distribution compare করে।
- **Scatter plot:** bivariate data-এর points plot করে relationship দেখায়।

এগুলো ছাড়া data শুধু সংখ্যায় দেখলে pattern বোঝা খুব কঠিন।

• Histogram

- A histogram is a graphical representation of the frequency distribution of continuous data.
 - Represented using rectangular bars
 - Shows how data is distributed across value ranges
 - X-axis: intervals (bins) of continuous values
 - Y-axis: frequency of observations
 - Used to visualize the distribution of numerical data
 - Bars touch each other because the data is continuous
- Example: Distribution of students' marks

২. Visualization of Data Distribution — Histogram

Histogram হলো **continuous numerical data**-এর frequency distribution-এর graphical representation।

বৈশিষ্ট্যগুলো:

- Rectangular bars দিয়ে তৈরি।
- X-axis-এ **intervals (bins)** থাকে — যেমন ১০০০০-৩০০০০, ৩০০০০-৫০০০০ ইত্যাদি।
- Y-axis-এ **frequency** (কতবার সেই range-এ data পড়েছে)।
- Bars গুলো একে অপরের সাথে **touch** করে কারণ data continuous (একটা value থেকে পরের value-এ কোনো gap নেই)।
- এটা দেখায় data কীভাবে value ranges-এ distributed আছে।

উদাহরণ: ছাত্রদের marks-এর distribution। ধরো marks ০-১০০। Histogram বানালে দেখা যাবে কতজন ৭০-৮০ এর মধ্যে, কতজন ৯০+ পেয়েছে। এক নজরে বোঝা যায় data skewed কি না, normal কি না।

একটা **histogram**-এর উদাহরণ:


X-axis: ১০০০০, ৩০০০০, ৫০০০০, ৭০০০০, ৯০০০০

Y-axis: frequency ০ থেকে ৩৫ পর্যন্ত।

এখানে দেখা যাচ্ছে কোন bin-এ সবচেয়ে বেশি data আছে।

Histogram Analysis

- Graph display of tabulated frequencies, shown as bars
- It shows what proportion of cases fall into each of several categories
- The categories are usually specified as non-overlapping intervals of some variable. The categories (bars) must be adjacent




৩. Histogram Analysis

- Graph display of tabulated frequencies, shown as bars.
- এটা দেখায় কত proportion of cases কোন category-এ পড়ছে।
- Categories গুলো **non-overlapping intervals** (যেমন ১০-২০, ২০-৩০)।
- Bars অবশ্যই **adjacent** হতে হবে (কোনো gap থাকবে না)।

Heavy point: Histogram দিয়ে আমরা data-এর **shape** বুঝতে পারি — symmetric, skewed left, skewed right, bimodal (দুইটা peak) ইত্যাদি। এটা descriptive statistics-এ খুব powerful tool।

৪. Histograms Often Tell More than Boxplots



দুটো histogram দেখানো হয়েছে (স্লাইডে left-এ) যাদের **same boxplot** আছে। অর্থাৎ:

- Min, Q₁, Median, Q₃, Max — সব একই।
- কিন্তু **data distribution** একদম আলাদা।

কেন এমন হয়?

Boxplot শুধু five-number summary দেখায়। কিন্তু histogram full distribution দেখায়।

একটা histogram normal distribution হতে পারে (একটা smooth bell curve), আরেকটা bimodal (দুইটা peak) হতে পারে — কিন্তু boxplot দুটোতেই একই দেখাবে।

Real-life example:

ধরো দুটো company-এর salary data।

- Company A: সবাই প্রায় ৫০,০০০ টাকা (normal)।
- Company B: অর্ধেক ২০,০০০ আর অর্ধেক ৮০,০০০ (bimodal)। দুটোর boxplot একই হবে কিন্তু histogram দেখলে বোঝা যাবে B-এ দুইটা গ্রুপ আছে। **Conclusion:** Histogram > Boxplot যখন full distribution জানতে চাও।

Categorical Data Visualization

- Bar Chart
 - Categorical data
 - Comparison between groups
 - Bars have gaps
- Example: Departments and the number of students

৫. Categorical Data Visualization — Bar Chart

Bar Chart ব্যবহার হয় **categorical data**-এর জন্য।


- Comparison between different groups দেখাতে।
- Bars-এর মাঝে **gaps** থাকে (কারণ categories আলাদা আলাদা)।
- উদাহরণ: বিভাগ অনুসারে ছাত্র সংখ্যা — CSE: ১২০, EEE: ৯০, ME: ৭০। Bars-এর height দেখলেই তুলনা হয়ে যায়।

৬. Bar chart / Bar Diagram

বৈশিষ্ট্য:

- Series of rectangular bars of **equal width**।
- সব bars একই **common base line**-এর উপর দাঁড়ায়।
- এক bar থেকে আরেক bar-এ **equal gap** থাকে।
- Bar **horizontal** অথবা **vertical** হতে পারে।

- Bar diagram consists of a series of rectangular bars of equal width
- The bars stand on common base line with equal gap between one bar and another
- The bar may be either horizontal or vertical



কখন ব্যবহার করব? যখন categories-এর মধ্যে comparison দরকার (যেমন: departments, blood groups, age groups)।

৭. Histogram vs Bar Chart (PAGE 15)

Feature	Histogram	Bar Chart
---------	-----------	-----------


Data type	Continuous (সংখ্যা যা যেকোনো value নিতে পারে)	Categorical (আলাদা আলাদা groups)
Bars	Touch each other (no gap)	Have gaps
Purpose	Distribution দেখানো (কীভাবে ছড়ানো)	Comparison দেখানো
Example	Exam scores (০-১০০)	Department enrollment (CSE, EEE)

মনে রাখার সহজ ট্রিক: Histogram = continuous + touch + distribution

Bar Chart = categorical + gap + comparison]

Quantile Based Visualization

- Displays all of the data (allowing the user to assess both the overall behavior and unusual occurrences)
- Plots **quantile** information
 - For a data x_i , data sorted in increasing order, f_i indicates that approximately 100 f_i % of the data are below or equal to the value x_i



Quantile Plot:

Quantile Plot হলো ডাটা অ্যানালাইসিসের একটি চমৎকার টুল। এটি মূলত আমাদের বুঝতে সাহায্য করে যে একটি ডেটাসেটের মানগুলো কীভাবে ছড়িয়ে আছে (Distribution) এবং নির্দিষ্ট কোনো পার্সেন্টাইলে ডেটার মান কত।

সহজ ভাষায় এর ব্যাখ্যা নিচে দেওয়া হলো:

কেন করি? (Why we use it)

আমরা সাধারণত গড় (Mean) দেখে সব বুঝতে পারি না। Quantile Plot নিচের বিষয়গুলো পরিষ্কার করে:

1. ডেটা ডিস্ট্রিবিউশন বুঝতে: ডেটা কি সমানভাবে ছড়িয়ে আছে, নাকি একদিকে বেশি ঝুঁকে আছে (Skewness)?
2. পার্সেন্টাইল বের করতে: যেমন—"৮০% ছাত্রের মার্কস কতর নিচে?" এটি গ্রাফ থেকে এক পলকেই দেখা যায়।
3. আউটলিয়ার চিনতে: ডেটার একদম শুরু বা শেষের দিকে অস্বাভাবিক কোনো মান আছে কি না।
4. তুলনা করতে: একাধিক ডেটাসেটের বিস্তৃতি কেমন, তা তুলনা করা সহজ হয়।

কীভাবে করি? (How to do it)

Quantile Plot তৈরি করার পদ্ধতিটি বেশ সহজ। নিচে ধাপগুলো দেওয়া হলো:

ধাপ ১: ডেটা সাজানো (**Sorting**) প্রথমে তোমার কাছে থাকা সব ডেটাকে ছোট থেকে বড় (Ascending order) ক্রমে সাজাতে হবে।

ধাপ ২: ফ্রিকোয়েন্সি বা পার্সেন্টাইল হিসাব করা প্রতিটি ডেটা পয়েন্টের জন্য একটি 'f-value' (Fractional rank) বের করতে হয়। এর সূত্র হলো:

$$f_i = \frac{i - 0.5}{n}$$

(এখানে i হলো ডেটার পজিশন এবং n হলো মোট ডেটার সংখ্যা)। এই f_i মানটি ০ থেকে ১ এর মধ্যে থাকে, যা মূলত ওই ডেটার পার্সেন্টাইল নির্দেশ করে।

ধাপ ৩: গ্রাফে প্লট করা

- **X-axis** (অণুভূমিক অক্ষ): এখানে থাকে f -value বা পার্সেন্টাইল (যেমন: ০.২৫, ০.৫০, ০.৭৫)।
- **Y-axis** (উল্লম্ব অক্ষ): এখানে থাকে ডেটার আসল মান (Data Values)।

একটি উদাহরণ দিয়ে বুঝুন

মনে করো ৫ জন ছাত্রের নম্বর হলো: ১০, ২০, ৩০, ৪০, ৫০।

এখানে $n = 5$ ।

- প্রথম ছাত্রের (১০) জন্য $f_1 = \frac{1 - 0.5}{5} = 0.1$ (অর্থাৎ ১০% পজিশন)।
- তৃতীয় ছাত্রের (৩০) জন্য $f_3 = \frac{3 - 0.5}{5} = 0.5$ (অর্থাৎ এটি মিডিয়ান বা ৫০% পজিশন)।


এখন তুমি যখন গ্রাফে X-অক্ষে 0.5 এবং Y-অক্ষে 30 পয়েন্টটি বসাবে, তখন সেটিই হবে তোমার Quantile Plot-এর একটি অংশ।

কিউ-কিউ প্লট (Q-Q Plot) এর সাথে পার্থক্য:

অনেকে Quantile Plot আর Q-Q Plot গুলিয়ে ফেলে।

- **Quantile Plot:** একটি মাত্র ডেটাসেটের ডিস্ট্রিবিউশন দেখায়।
- **Q-Q Plot:** দুটি আলাদা ডেটাসেট বা একটি থিওরিটিক্যাল ডিস্ট্রিবিউশনের (যেমন Normal Distribution) সাথে তুলনা করতে ব্যবহৃত হয়।

সারাংশ: Quantile Plot হলো ডেটার একটি "প্রগ্রেস কার্ড" যা আমাদের বলে দেয় কোন পজিশনে ডেটার মান কত।



এই ছবিগুলো মূলত **Q-Q Plot (Quantile-Quantile Plot)** এর। সাধারণ Quantile Plot এ কোনো রেফারেন্স লাইন থাকে না, কিন্তু Q-Q Plot এ আমরা আমাদের ডেটাকে একটি আদর্শ ডিস্ট্রিবিউশনের (সাধারণত Normal Distribution) সাথে তুলনা করি। আগে Q-Q Plot সহজ করে বুঝে নিই, তারপর তোমার ছবিগুলো ব্যাখ্যা করছি। আমরা দুটি আসল ডেটাসেট (**Sample 1 vs Sample 2**) তুলনা করি, তখন এই ৫টি গ্রাফের মানে দাঁড়াবে এমন যে— "প্রথম ডেটাসেটটির তুলনায় দ্বিতীয় ডেটাসেটটি দেখতে কেমন?"

ধরে নাও, তোমার $\$X\$$ -অক্ষে আছে **Dataset A** এবং $\$Y\$$ -অক্ষে আছে **Dataset B**। এবার এই ৫টি গ্রাফের ইন্টারপ্রিটেশন বুঝে নাও:

(a) Normal / Linear (একই রকম)

বিন্দুগুলো যখন একদম সোজা লাইনে থাকে, তার মানে হলো Dataset A এবং Dataset B-এর ডিস্ট্রিবিউশন একই রকম। এদের গড় (Mean) বা ডাটা ছড়িয়ে থাকার ধরণ (Variance) আলাদা হতে পারে, কিন্তু এদের "শেপ" বা আকৃতি হবে এক।

(b) Skewed to the Left (A-এর তুলনায় B বামে ঝুঁকে)

যদি গ্রাফটি নিচের দিকে একটু কার্ভ হয়ে থাকে (উল্টো 'S' এর মতো), তবে এর মানে হলো:

- Dataset A-এর তুলনায় Dataset B-তে ছোট মানের (**lower values**) সংখ্যা বেশি।
- অর্থাৎ Dataset B-এর ডিস্ট্রিবিউশনটি Dataset A-এর তুলনায় বাম দিকে বেশি ঝুঁকে আছে।

(c) Skewed to the Right (A-এর তুলনায় B ডানে ঝুঁকে)

এটি (b) এর ঠিক উল্টো। গ্রাফটি যদি ওপরের দিকে ধনুকের মতো বেঁকে যায়, তার মানে:

- Dataset A-এর তুলনায় Dataset B-তে বড় মানের (**higher values**) সংখ্যা অনেক বেশি।
- সহজ কথায়, Dataset B-এর ডাটাগুলো ডান দিকে বেশি বিস্তৃত।

(d) Thick Tails (A-এর তুলনায় B-তে আউটলায়ার বেশি)

এখানে বিন্দুগুলো মাঝখানে লাইনের সাথে থাকলেও দুই প্রান্তে (শুরুতে এবং শেষে) লাইন থেকে অনেক দূরে চলে গেছে। এর মানে:

- Dataset A-এর তুলনায় Dataset B-তে চরম মান বা **Outliers** অনেক বেশি।
- অর্থাৎ Dataset B-এর "লেজ" বা Tails অনেক মোটা; এখানে অনেক বেশি খাটো বা অনেক বেশি লম্বা মানুষ (আগের উদাহরণ অনুযায়ী) আছে যা Dataset A-তে নেই।


(e) Thin Tails (A-এর তুলনায় B-তে আউটলায়ার কম)

এটি (d) এর একদম উল্টো। বিন্দুগুলো মাঝখানে ছড়িয়ে থাকলেও দুই প্রান্তে লাইনের খুব কাছাকাছি চলে আসে। এর মানে:

- Dataset A-এর তুলনায় Dataset B-তে আউটলায়ার একদম নেই বললেই চলে।
- Dataset B-এর ডাটাগুলো অনেক বেশি "সংকুচিত" বা মাঝখানের দিকে সীমাবদ্ধ, যা Dataset A-এর মতো অতটা ছড়ানো নয়।

Quantile-Quantile (Q-Q) Plot

- Graphs the quantiles of one univariate distribution against the corresponding quantiles of another
- View: Is there is a shift in going from one distribution to another?
- Example shows unit price of items sold at Branch 1 vs. Branch 2 for each quantile. Unit prices of items sold at Branch 1 tend to be lower than those at Branch 2.



১. Quantile-Quantile (Q-Q) Plot

Q-Q Plot বা **Quantile-Quantile Plot** হলো একটি শক্তিশালী স্ট্যাটিস্টিক্যাল টুল যা মূলত দুটি ডাটা সেটের ডিস্ট্রিবিউশন (Distribution) তুলনা করার জন্য ব্যবহৃত হয়। সহজ কথায়, এটি আমাদের বলে দেয়— "আমার হাতের ডাটাগুলো কি কোনো নির্দিষ্ট থিওরিটিক্যাল ডিস্ট্রিবিউশন (যেমন: Normal Distribution) মেনে চলছে?"

নিচে এর বিস্তারিত আলোচনা করা হলো:

১. Q-Q Plot কীভাবে কাজ করে? (How it works)

একটি Q-Q Plot তৈরি করতে মূলত দুটি জিনিস লাগে:

- **তাত্ত্বিক কোয়ান্টাইল (Theoretical Quantiles):** একটি আদর্শ ডিস্ট্রিবিউশন (যেমন Normal Distribution) থেকে পাওয়া মান।
- **নমুনার কোয়ান্টাইল (Sample Quantiles):** তোমার সংগৃহীত ডাটা থেকে পাওয়া মান।

গ্রাফের XX -অক্ষ থাকে তাত্ত্বিক মান এবং YY -অক্ষ থাকে তোমার ডাটার মান। যদি তোমার ডাটা ওই আদর্শ ডিস্ট্রিবিউশন মেনে চলে, তবে পয়েন্টগুলো একটি 45° সোজা লাইন তৈরি করবে।

২. কেন আমরা Q-Q Plot করি? (Significance)

অনেক স্ট্যাটিস্টিক্যাল টেস্ট (যেমন T-test বা ANOVA) করার আগে ধরে নেওয়া হয় যে ডাটা **Normal Distribution** মেনে চলে। Q-Q Plot হলো সবচেয়ে সহজ উপায় এটি পরীক্ষা করার।

- **Normal** কি না তা বুঝতে: পয়েন্টগুলো লাইনের ওপর থাকলে ডাটা Normal।
- **আউটলায়ার (Outliers)** চিনতে: যদি কোনো পয়েন্ট লাইন থেকে অনেক দূরে চলে যায়, সেটি আউটলায়ার।
- **Skewness** বুঝতে: ডাটা কি বাঁকা? এটি গ্রাফের বক্রতা দেখে বোঝা যায়।

৩. গ্রাফ দেখে ডাটা চেনার উপায় (Interpretation)

গ্রাফের অবস্থা	এর মানে কী?
পয়েন্টগুলো সোজা লাইনে আছে	ডাটা একদম Normal ।
লাইনটি ওপরের দিকে 'S' এর মতো বাঁকানো	ডাটায় Heavy Tails আছে (অর্থাৎ আউটলায়ার বেশি)।
লাইনটি নিচের দিকে 'S' এর মতো বাঁকানো	ডাটায় Light Tails আছে।
বক্ররেখা (Curve) ওপরের দিকে বাঁকানো	ডাটা Right Skewed (ডান দিকে হেলে আছে)।
বক্ররেখা নিচের দিকে বাঁকানো	ডাটা Left Skewed (বাম দিকে হেলে আছে)।

৪. Q-Q Plot করার ধাপসমূহ (Step-by-Step)

১. ডেটাসেট (Data Samples)

- **City A (X-axis):** 150, 170, 160, 155, 165 (সেমি)
- **City B (Y-axis):** 152, 172, 162, 157, 167 (সেমি)

২. ধাপগুলো অনুসরণ করি (How to Plot)

ধাপ ১: ছোট থেকে বড় সাজানো (**Sorting**) যেকোনো Q-Q Plot এর প্রথম শর্তই হলো ডেটা সর্ট করা।


- City A (Sorted): **150, 155, 160, 165, 170**
- City B (Sorted): **152, 157, 162, 167, 172**

ধাপ ২: জোড়া তৈরি করা (**Pairing**) এখন আমরা একই র‍্যাঙ্কের বা একই কোয়ান্টাইলের মানগুলোকে জোড়া দেব।

- ১ম জোড়া: (150, 152)
- ২য় জোড়া: (155, 157)
- ৩য় জোড়া: (160, 162)
- ৪র্থ জোড়া: (165, 167)

- ৫ম জোড়া: (170, 172)

ধাপ ৩: গ্রাফে প্লট করা এখন এই (X, Y) কোঅর্ডিনেটগুলো গ্রাফে বসায়।




Heavy information: Q-Q plot খুব powerful কারণ এটা দিয়ে normality check করা যায় (normal distribution-এর সাথে compare করে) অথবা দুটো sample-এর distribution একই কি না তা পরীক্ষা করা যায়। Machine learning-এ feature transformation-এর পরে ব্যবহার হয়।

২. Relationship Visualization: Scatter Plot এর মূল কাজ (Function)

এর প্রধান কাজ হলো **Correlation** বা সম্পর্ক খুঁজে বের করা। অর্থাৎ, একটি ভেরিয়েবল পরিবর্তন করলে অন্যটির ওপর কী প্রভাব পড়ে তা দেখা।

- **Positive Correlation:** যদি দেখা যায় X বাড়লে Y-ও বাড়ছে (বিন্দুগুলো নিচ থেকে ওপরের দিকে যাচ্ছে), তবে এটি পজিটিভ সম্পর্ক। (যেমন: পড়ার সময় বাড়লে পরীক্ষার মার্কস বাড়বে)।
- **Negative Correlation:** যদি X বাড়লে Y কমে (বিন্দুগুলো ওপর থেকে নিচের দিকে নামছে), তবে এটি নেগেটিভ সম্পর্ক। (যেমন: গাড়ির স্পিড বাড়লে গন্তব্যে পৌঁছানোর সময় কমে)।
- **No Correlation:** যদি বিন্দুগুলো একদম এলোমেলোভাবে ছড়িয়ে থাকে এবং কোনো নির্দিষ্ট দিক বোঝা না যায়, তবে তাদের মধ্যে কোনো সম্পর্ক নেই।


- Provides a first look at bivariate data to see clusters of points, outliers, etc
- Each pair of values is treated as a pair of coordinates and plotted as points in the plane



২. কেন আমরা Scatter Plot ব্যবহার করি?

- প্যাটার্ন খুঁজে বের করা: ডাটাগুলো কি কোনো লিনিয়ার (সরলরৈখিক) প্যাটার্ন মেনে চলে নাকি কার্ভ (বক্ররেখা) তৈরি করে, তা বোঝা যায়।
- আউটলায়ার (Outliers) শনাক্ত করা: পুরো ডাটা সেট থেকে যদি কোনো একটি বিন্দু অনেক দূরে থাকে, তবে সেটি সহজেই চোখে পড়ে। এই অস্বাভাবিক পয়েন্টগুলো খুঁজে বের করা স্ক্যাটার প্লটের অন্যতম বড় কাজ।

- সম্পর্কের গভীরতা বোঝা: বিন্দুগুলো যদি খুব কাছাকাছি বা ঘন হয়ে থাকে, তবে বোঝা যায় সম্পর্কটি অনেক শক্তিশালী। আর যদি অনেক দূরে দূরে থাকে, তবে সম্পর্কটি দুর্বল।
- গ্রুপিং বা ক্লাস্টারিং: কখনো কখনো দেখা যায় ডাটা পয়েন্টগুলো আলাদা আলাদা দলা বা 'Cluster' তৈরি করে আছে। এটি থেকে বোঝা যায় যে ডেটার ভেতরে আলাদা আলাদা গ্রুপ আছে।



৩. Positively and Negatively Correlated Data

Scatter plot-এ correlation দেখা যায়:

- **Positively Correlated:** Left half থেকে right half-এ points উপরের দিকে যায়। অর্থাৎ একটা variable বাড়লে আরেকটা-ও বাড়ে। উদাহরণ: Advertising budget বাড়লে Sales বাড়ে।
- **Negatively Correlated:** Left থেকে right-এ points নিচের দিকে যায়। একটা বাড়লে আরেকটা কমে। উদাহরণ: Price বাড়লে Demand কমে।
- **Uncorrelated Data:** Points **randomly** ছড়ানো — কোনো pattern নেই। কোনো relationship নেই। উদাহরণ: Student ID number vs Exam marks — কোনো link নেই।

Heavy point: Correlation দেখে আমরা শুধু relationship বুঝি, কিন্তু causation প্রমাণ হয় না। (যেমন ice-cream sales আর drowning-এর positive correlation, কিন্তু summer-এর কারণে।)

8. Frequency Curve

Frequency Curve হলো একটি মসৃণ রেখা (Smooth line) যা কোনো ডাটা সেটের ডিস্ট্রিবিউশন বা বিস্তৃতি দেখায়। এটি মূলত একটি Histogram-এর প্রতিটি বারের মধ্যবিন্দুগুলোকে একটি বাঁকানো রেখা দিয়ে যোগ করে তৈরি করা হয় (একে অনেক সময় Frequency Polygon-এর স্মুথ ভার্সনও বলা হয়)।

২. Histogram থাকতেও এটি কেন ব্যবহার করি? (Why we use it)

ক) ডাটার ধারাবাহিকতা (**Continuity**) বোঝাতে

Histogram ডাটাকে ছোট ছোট ব্লকে (Bins) ভাগ করে ফেলে, যা দেখতে সিঁড়ির মতো লাগে। কিন্তু বাস্তবে অনেক ডাটা (যেমন: মানুষের উচ্চতা, ওজন বা তাপমাত্রা) সিঁড়ির মতো লাফিয়ে বাড়ে না, বরং ধারাবাহিকভাবে বাড়ে। Frequency Curve এই ধারাবাহিকতা বা **Continuity** বজায় রাখে।

খ) ডিস্ট্রিবিউশনের ধরন (**Shape**) সহজে বুঝতে

একটি Histogram-এ অনেকগুলো খাঁজকাটা বার থাকে। Frequency Curve সেই খাঁজগুলো মুছে দিয়ে আমাদের পরিষ্কারভাবে দেখায় যে ডাটাটি:

- **Normal** (বেল আকৃতির)?
- **Skewed** (একদিকে ঝুঁকে আছে)? নাকি
- **Bimodal** (দুটি চূড়া আছে)?

গ) একাধিক ডাটা সেটের তুলনা করতে

এটিই সবচেয়ে বড় কারণ। ধরো, তুমি ১০টি আলাদা ক্লাসের স্টুডেন্টদের রেজাল্ট তুলনা করতে চাও। তুমি যদি ১০টি Histogram একটির ওপর আরেকটি বসাও, তবে কিছুই বোঝা যাবে না (সব বার জট পাকিয়ে যাবে)। কিন্তু তুমি যদি ১০টি **Frequency Curve** একটির ওপর আরেকটি বসাও, তবে খুব সহজেই বোঝা যাবে কোন ক্লাসের পারফরম্যান্স কেমন।



[Image comparing multiple frequency curves on one graph]

ঘ) ভবিষ্যৎবাণী বা ম্যাথমেটিক্যাল মডেলিং

পরিসংখ্যানবিদরা যখন ডাটা নিয়ে ভবিষ্যৎবাণী করেন, তখন তারা Histogram-এর বার ব্যবহার না করে একটি Smooth Curve ব্যবহার করেন। কারণ মসৃণ রেখার ওপর গাণিতিক সূত্র (Calculus) প্রয়োগ করা অনেক সহজ।

Frequency curve

- Variables is taken along the X-axis and frequencies along Y-axis
- Frequencies are plotted against the class mid-values and then these points are joined by a smooth curve
- Total area under the frequency curve represents total frequency



৫. Line Graphs (PAGE 22)

Line Graph দুটো variable-এর comparison দেখাতে ব্যবহার হয়।

- X-axis = **time** (দিন, মাস, বছর)।
- Y-axis = **percentage** বা **quantity**।


বৈশিষ্ট্য:

- Change in direction দেখায়।
- Trend বোঝায় — কোনো event সময়ের সাথে **increased** নাকি **decreased**।

উদাহরণ: গত ১২ মাসের company sales — line উপরে গেলে বোঝা যায় sales বাড়ছে। Stock price trend দেখাতে সবচেয়ে popular।

Line graphs

- Line graphs are used to display the comparison between two variables which are plotted on the X-axis and Y-axis
- The X-axis represents measures of time, while the Y-axis represents percentage or measures of quantity
- Line graphs displays a change in direction
- It shows trend of an event occurring over a period of time to know whether it is increased or decreased.



৬. Pie Diagram

Pie Diagram discrete qualitative data (categorical) দেখাতে ব্যবহার হয়।

যেমন: blood groups, age group, causes of mortality ইত্যাদি। We can identify if there have any class imbalance because it is important for model training. For example: 10 cat picture, 1 Dog picture


কীভাবে তৈরি হয়:

- Whole circle = 360° ।
- প্রত্যেক group-এর frequency অনুপাতে **sector**-এর **angle** তৈরি হয়।
- Area of the sector = frequency-এর প্রতিনিধিত্ব করে।

উদাহরণ: একটা class-এর blood group — A+, B+, O+ ইত্যাদি। Pie দেখলেই কোন group সবচেয়ে বেশি স্পষ্ট হয়।

সতর্কতা: Pie chart শুধু যখন ৫-৬টা category থাকে তখন ভালো; বেশি হলে cluttered হয়ে যায়।

- Presenting discrete data of qualitative characteristics such as blood groups, Age group, causes of mortality etc.
- The frequencies of the groups are shown in a circle
- Degrees of angle denote the frequency and area of the sector



৭. Heat Map (PAGE 24)

Heatmap হলো data visualization technique যেখানে **values** কে **colors** দিয়ে **represent** করা হয়।



Key Characteristics:

- প্রত্যেক cell একটা value (matrix বা table-এর)।
- **Darker / stronger color** = higher value।
- **Lighter color** = lower value।
- খুব দ্রুত pattern, relationship, intensity বোঝা যায়।

Common Use:

- Machine learning-এ **correlation matrix** (কোন features একে অপরের সাথে কতটা correlated)।
- **Confusion matrix** (classification model-এ কতটা সঠিক prediction হয়েছে)।

উদাহরণ: ১০টা feature-এর correlation heatmap বানালে এক নজরে দেখা যাবে কোন দুটো feature খুব strongly positive correlated (dark red) বা negative (dark blue)। Data scientist-দের daily tool।



Geometric Projection Visualization

- Visualization of geometric transformations and projections of the data
- Challenge
 - How to visualize a high-dimensional space on a 2-D display?
- Methods
 - Scatterplot and scatterplot matrices
 - Parallel coordinates

১. Geometric Projection Visualization

Geometric Projection Visualization সহজ কথায় হলো একটি কৌশল, যা আমাদের অনেকগুলো কলাম বা ভেরিয়েবল (High-dimensional data) সম্বলিত জটিল ডেটাকে আমাদের কম্পিউটারের ২-মাত্রার (2D) স্ক্রিনে দেখতে সাহায্য করে।

নিচে এর মূল ধারণা এবং তোমার উল্লেখ করা পদ্ধতিগুলো বিস্তারিত বুঝিয়ে বলছি:

১. মূল চ্যালেঞ্জ: ডাইমেনশন সমস্যা

কল্পনা করো, তোমার কাছে একজন কাস্টমারের ৫টি তথ্য আছে: বয়স, আয়, খরচ, ক্রেডিট স্কোর এবং লোকেশন।

- আমরা সাধারণ গ্রাফে সর্বোচ্চ ৩টি অক্ষ (X , Y , Z) দেখাতে পারি।
- ৫টি বা ১০টি তথ্যকে একসাথে এক স্ক্রিনে দেখানো সাধারণ গ্রাফ দিয়ে অসম্ভব।


Geometric Projection এই ১০টি ডাইমেনশনকে জ্যামিতিক উপায়ে "প্রজেক্ট" বা ভাঁজ করে ২ডি স্ক্রিনে নিয়ে আসে, যাতে আমরা মানুষের চোখে তা দেখে প্যাটার্ন বুঝতে পারি।

Methods (পদ্ধতি):

- **Scatterplot and Scatterplot Matrices**
- **Parallel Coordinates**

Heavy information: এই techniques ছাড়া multi-dimensional data (যেমন customer-এর age, income, spending, location, purchase history) দেখা অসম্ভব। Projection করে আমরা hidden patterns খুঁজি।

Scatterplot Matrices



Matrix of scatterplots (x-y-diagrams) of the k-dim. data [total of $(k^2/2-k)$ scatterplots]

২. Scatterplot Matrices

Scatterplot Matrix (SPLOM) হলো অনেকগুলো স্ক্যাটার প্লটের একটি সুশৃঙ্খল গ্রিড বা টেবিল। যখন আমাদের ডাটায় দুইয়ের অধিক ভেরিয়েবল (যেমন ৩ থেকে ১০টি কলাম) থাকে, তখন সবগুলোর মধ্যে একে অপরের সম্পর্ক একবারে দেখার জন্য এটি সেরা উপায়।

সহজ কথায়, এটি হলো ভেরিয়েবলগুলোর মধ্যে একটি "সাম্বন্ধাকার টেবিল", যেখানে সবাই সবার সাথে একবার করে দেখা করে।

১. কেন করে? (Why do we do it?)

- **Pairwise Correlation:** ধরো তোমার কাছে Income, Age, এবং Spending-এর ডাটা আছে। তুমি একসাথে দেখতে চাও:
 1. আয়ের সাথে বয়সের সম্পর্ক।
 2. আয়ের সাথে খরচের সম্পর্ক।
 3. বয়সের সাথে খরচের সম্পর্ক।
- এক নজরে সব দেখা: আলাদা আলাদা ১০টা গ্রাফ না বানিয়ে একটি ম্যাট্রিক্সেই সব রিলেশনশিপ বোঝা যায়।
- **Cluster & Outlier Detection:** ডাটায় কোনো গ্রুপ আছে কি না বা কোনো পয়েন্ট অস্বাভাবিক কি না, তা সব অ্যাক্সিসবিউটের সাপেক্ষে চেক করা যায়।

২. কীভাবে করে? (How to make/structure it?)

ধরা যাক, তোমার ডাটায় k সংখ্যক ভেরিয়েবল বা অ্যাক্সিসবিউট আছে।

- ম্যাট্রিক্স সাইজ: এটি একটি $k \times k$ সাইজের টেবিল হবে।
- **Diagonal** (কোণাকুণি): ম্যাট্রিক্সের মাঝখানের কোণাকুণি ঘরগুলোতে সাধারণত ভেরিয়েবলগুলোর নাম লেখা থাকে। অনেক সময় এখানে **Histogram** বা **Density Plot** দেখানো হয় যাতে ওই নির্দিষ্ট ভেরিয়েবলটির নিজস্ব ডিস্ট্রিবিউশন বোঝা যায়।
- **Plots:** ডায়াগোনাালের উপরের এবং নিচের ঘরগুলোতে জোড়ায় জোড়ায় স্ক্যাটার প্লট থাকে।
 - Row 1, Column 2-এর বক্সে থাকবে (Attribute 1 vs Attribute 2)-এর প্লট।
- সূত্র: যদি k টা ভেরিয়েবল থাকে, তবে ইউনিক প্লট সংখ্যা হবে $\frac{k(k-1)}{2}$ । (কারণ উপরের ত্রিভুজ আর নিচের ত্রিভুজ আসলে একই তথ্যের প্রতিফলন, শুধু অক্ষগুলো অদলবদল করা)।

৩. একটি বাস্তব উদাহরণ (Details Breakdown)

ধরো ৪টি অ্যাক্সিসবিউট আছে: **Age, BMI, Glucose, Insulin**।

1. ম্যাট্রিক্সটি হবে 8x8 গ্রিড।
2. **Row 1 (Age):** এই সারির বাকি ঘরগুলোতে থাকবে Age vs BMI, Age vs Glucose, এবং Age vs Insulin।
3. **Visual Check:** তুমি যদি দেখো "Age vs Glucose" বক্সের বিন্দুগুলো নিচ থেকে উপরের দিকে যাচ্ছে, তবে বুঝবে বয়স বাড়লে গ্লুকোজ লেভেল বাড়ে।
4. **Symmetry:** ম্যাট্রিক্সের উপরের অর্ধাংশ আর নিচের অর্ধাংশ আয়নার মতো। অর্থাৎ (Age vs BMI) আর (BMI vs Age) একই তথ্য দেয়, শুধু X এবং Y অক্ষ অদলবদল হয়।


৪. কখন এটি ব্যবহার করা কঠিন? (Limitations)

- অ্যাট্রিবিউট সংখ্যা বেশি হলে: যদি তোমার ২০টি ভেরিয়েবল থাকে, তবে ম্যাট্রিক্সে ৪০০টি ঘর হবে! তখন প্রতিটি ছোট প্লট এত ক্ষুদ্র দেখাবে যে কিছুই বোঝা যাবে না। এজন্য এটি সাধারণত ৩ থেকে ৮-১০টি ভেরিয়েবলের জন্য সবচেয়ে ভালো কাজ করে।
- **Overplotting:** যদি ডাটা পয়েন্ট লাখ লাখ হয়, তবে বিন্দুগুলো জট পাকিয়ে যায়। তখন বিন্দুর বদলে **Hexbin** বা **Heatmap** স্টাইল ব্যবহার করতে হয়।

সারসংক্ষেপ:

Scatterplot Matrix হলো "**Multivariate Analysis**"-এর প্রথম ধাপ। এটি আমাদের বলে দেয় কোন ভেরিয়েবলগুলো একে অপরের সাথে "বন্ধুত্ব" (Positive Correlation) করছে, কারা "শত্রুতা" (Negative Correlation) করছে, আর কারা একে অপরের থেকে "বিচ্ছিন্ন" (No Correlation)।

- n equidistant axes which are parallel to one of the screen axes and correspond to the attributes
- The axes are scaled to the [minimum, maximum]: range of the corresponding attribute
- Every data item corresponds to a polygonal line which intersects each of the axes at the point which corresponds to the value for the attribute



৩. Parallel Coordinates

Parallel Coordinates হলো হাই-ডাইমেনশনাল ডাটা (High-dimensional data) দেখার অন্যতম সেরা পদ্ধতি। যখন আমাদের ডাটায় অনেকগুলো কলাম (যেমন ১০-২০টি বৈশিষ্ট্য) থাকে, তখন সেগুলোকে সাধারণ X-Y গ্রাফে দেখানো অসম্ভব হয়ে পড়ে। প্যারালাল কোঅর্ডিনেট এই সমস্যাটি চমৎকারভাবে সমাধান করে।

নিচে এটি সহজভাবে বুঝিয়ে দিচ্ছি:

১. প্যারালাল কোঅর্ডিনেট আসলে কী?

সাধারণ গ্রাফে অক্ষগুলো (Axes) একে অপরের সাথে লম্ব (\$90^\circ\$) ভাবে থাকে। কিন্তু প্যারালাল কোঅর্ডিনেটে অক্ষগুলো একে অপরের সমান্তরাল (**Parallel**) ভাবে থাড়া হয়ে দাঁড়িয়ে থাকে।

- প্রতিটি থাড়া লাইন (Vertical line) হলো একটি অ্যাট্রিবিউট বা ভেরিয়েবল।
- প্রতিটি অক্ষের একটি স্কেল থাকে (নিচে সর্বনিম্ন মান, উপরে সর্বোচ্চ মান)।

২. এটি কীভাবে কাজ করে? (How it works)

ধরো, তোমার কাছে ৫ জন মানুষের ডাটা আছে যাদের বয়স (Age), আয় (Income), এবং ক্রেডিট স্কোর (Credit Score) আছে।

1. অক্ষ স্থাপন: তুমি স্ক্রিনে পাশাপাশি ৩টি সমান্তরাল খাড়া লাইন আঁকলে (একটি বয়সের জন্য, একটি আয়ের জন্য, একটি ক্রেডিট স্কোরের জন্য)।
2. ডাটা পয়েন্ট বসানো: প্রতিটি মানুষের জন্য একটি করে আঁকাবাঁকা রেখা (**Polygonal Line**) আঁকা হয়।
3. সংযোগ: ওই রেখাটি 'বয়স' অক্ষকে তার বয়সের পয়েন্টে, 'আয়' অক্ষকে তার আয়ের পয়েন্টে এবং 'ক্রেডিট স্কোর' অক্ষকে তার স্কোরের পয়েন্টে ছেদ করে চলে যায়।

৩. কখন এটি ব্যবহার করবে? (Why use it?)

- **প্যাটার্ন খোঁজা (Finding Patterns):** যদি দেখা অনেকগুলো লাইন একই রকম ভাবে ওপর-নিচে যাচ্ছে, তবে বুঝবে ওই মানুষগুলোর স্বভাব বা ডাটার ধরন একই।
- **ক্লাস্টার (Clustering):** যদি একগুচ্ছ লাইন একটি নির্দিষ্ট এলাকায় জড়ো হয়, তবে বোঝা যায় সেখানে একটি গ্রুপ বা ক্লাস্টার আছে।
- **আউটলায়ার (Outliers):** যদি একটি লাইন সবার চেয়ে আলাদা ভাবে অদ্ভুত কোনো দিকে চলে যায়, তবে সেটিই হলো আউটলায়ার।
- **অ্যাট্রিবিউট রিলেশন:** যদি দুটি অক্ষের মধ্যে লাইনগুলো সমান্তরাল ভাবে যায়, তবে তাদের মধ্যে **Positive Correlation** আছে। আর যদি লাইনগুলো মাঝখানে 'X' এর মতো ক্রস করে, তবে তাদের মধ্যে **Negative Correlation** আছে।

৪. বাস্তব উদাহরণ (Example)

ধরা যাক তুমি অনেকগুলো গাড়ির ডাটা দেখছ। তোমার অক্ষগুলো হলো: **Price, Horsepower, Mileage**, এবং **Weight**।

- একটি দামী স্পোর্টস কারের লাইনটি হয়তো **Price** অক্ষের খুব উপরে থাকবে, **Horsepower** অক্ষের খুব উপরে থাকবে, কিন্তু **Mileage** অক্ষের একদম নিচে থাকবে।
- এই একটি আঁকাবাঁকা লাইন দেখেই তুমি গাড়িটির পুরো "চরিত্র" বুঝে ফেললে।

৫. এর সীমাবদ্ধতা (Limitations)

প্যারালল কোঅর্ডিনেটের একটি বড় সমস্যা হলো **"Visual Clutter"** বা জটলা। যদি ডাটায় হাজার হাজার মানুষের তথ্য থাকে, তবে গ্রাফটি দেখতে একটি সুতার বল বা 'Hairball' এর মতো হয়ে যায়।

সমাধান: আধুনিক টুলগুলোতে লাইনগুলোকে আলাদা আলাদা রঙ (Color coding) করা হয় বা মাউস দিয়ে নির্দিষ্ট রেঞ্জ সিলেক্ট (Brushing) করে জটলা কমানো হয়।

সহজ কথায়: প্যারালল কোঅর্ডিনেট হলো ডাটার একটি "প্রোফাইল ভিউ"। এটি প্রতিটি ডেটা পয়েন্টকে একটি ইউনিক সিগনেচার বা আঁকাবাঁকা রেখার মাধ্যমে ফুটিয়ে তোলে।

8. Hierarchical Visualization Techniques

Hierarchical Visualization মূলত ব্যবহার করা হয় যখন আপনার ডাটায় একটি "বাবা-সন্তান" সম্পর্ক বা হায়ারার্কি থাকে। যেমন: একটি দেশ → তার বিভাগ → জেলা → উপজেলা। অথবা একটি বড় কোম্পানি → ডিপার্টমেন্ট → টিম → কর্মী।


যখন সাধারণ চার্টে এই গভীর সম্পর্কগুলো দেখানো যায় না, তখন আমরা নিচের পদ্ধতিগুলো ব্যবহার করি:

- Worlds-within-Worlds
- Tree-Map

এটা ব্যবহার হয় যখন data-এ hierarchy আছে (যেমন company-এর department → team → employee)।

Worlds-within-Worlds

- Assign the function and two most important parameters to innermost world
- Fix all other parameters at constant values - draw other (1 or 2 or 3 dimensional worlds choosing these as the axes)
- Software that uses this paradigm



৫. Worlds-within-Worlds

এটি একটু অ্যাডভান্সড বা জটিল পদ্ধতি। একে "n-Vision" ও বলা হয়। এটি মূলত হাই-ডাইমেনশনাল ডেটাকে ভিজুয়ালাইজ করার জন্য একটির ভেতর আরেকটি কোঅর্ডিনেট সিস্টেম ব্যবহার করে।

- কীভাবে কাজ করে: * ধরুন আপনার কাছে ৩টি ডাইমেনশন আছে। আপনি একটি ৩ডি স্পেস তৈরি করলেন।
 - এখন ওই ৩ডি স্পেসের ভেতরে একটি নির্দিষ্ট পয়েন্টে আপনি আরেকটি ছোট ৩ডি গ্রাফ বা কোঅর্ডিনেট সিস্টেম বসিয়ে দিলেন।
 - এভাবে "একটি জগতের ভেতরে আরেকটি জগত" তৈরি করে অনেকগুলো ডাইমেনশনকে একসাথে দেখা যায়।
- কেন ব্যবহার করি: সাধারণত গাণিতিক ফাংশন বা সায়েন্টিফিক ডেটা এনালিসিসের ক্ষেত্রে যেখানে অনেকগুলো ভেরিয়েবল একে অপরের ওপর নির্ভর করে, সেখানে এটি ব্যবহার হয়।

Worlds-within-Worlds একটা interactive visualization paradigm।

কীভাবে কাজ করে:

- **Innermost world**-এ assign করা হয় **function + two most important parameters**।
- বাকি সব parameters fix করে রাখা হয় constant value-এ।
- তারপর outer worlds বানানো হয় — ১D, ২D বা ৩D — বাকি parameters-কে axes হিসেবে ব্যবহার করে।

উদাহরণ:

ধরো function = Sales Prediction।

Innermost world-এ দুটো param: Advertising Budget ও Price।

বাকি param (Season, Region) fix করে outer world বানানো হয়।


এভাবে nested worlds তৈরি করে user interactive করে explore করতে পারে।

Software: এই paradigm ব্যবহার করে অনেক specialized visualization software আছে (স্লাইডে উল্লেখ আছে)।

সুবিধা: High-dimensional parameter space-কে step-by-step explore করা যায়।

Tree-Maps

- Treemaps display hierarchical (tree-structured) data as a set of nested rectangles. Each branch of the tree is given a rectangle, which is then tiled with smaller rectangles representing sub-branches.



CSE, BUET

৬. Tree-Maps

Tree-map মূলত পুরো স্ক্রিনকে বড় একটি আয়তক্ষেত্র (Rectangle) হিসেবে ধরে নেয় এবং সেটিকে ছোট ছোট বক্সে ভাগ করে ডেটা দেখায়।

- কীভাবে কাজ করে: * প্রতিটি বক্সের আয়তন (**Size**) নির্ভর করে তার ভ্যালুর ওপর (যেমন: যে ডিপার্টমেন্টের লাভ বেশি, তার বক্স বড় হবে)।
 - বক্সের রঙ (**Color**) দিয়ে অন্য একটি বৈশিষ্ট্য বোঝানো হয় (যেমন: লাল মানে লস, সবুজ মানে লাভ)।
 - নেস্টিং: একটি বড় বক্সের ভেতরে অনেকগুলো ছোট বক্স থাকে, যা বোঝায় যে ওই ছোট জিনিসগুলো বড়টির অংশ।
- কেন ব্যবহার করি: যখন আপনার কাছে হাজার হাজার আইটেম থাকে এবং আপনি এক নজরে দেখতে চান সবচাইতে বড় অংশ কোনটি দখল করে আছে। (যেমন: আপনার কম্পিউটারের হার্ডড্রাইভের কোন ফোল্ডার কতটুকু জায়গা খাচ্ছে তা দেখতে এটি সেরা)।

Tree-Maps hierarchical (tree-structured) data দেখানোর সবচেয়ে popular technique।

কীভাবে তৈরি হয়:

- পুরো data tree-কে **nested rectangles** দিয়ে represent করা হয়।

- প্রত্যেক **branch** একটা বড় rectangle পায়।
- তারপর সেই rectangle-কে **smaller rectangles** দিয়ে tile করা হয় — যা sub-branches-কে represent করে।
- Rectangle-এর **size** সাধারণত value (যেমন sales, file size) অনুপাতে হয়।
- Color দিয়ে আরেকটা dimension যোগ করা যায় (যেমন profit = green, loss = red)।

উদাহরণ:

Company-এর organizational hierarchy:

- বড় rectangle = Whole Company
- ভিতরে ছোট rectangle = Departments (CSE, EEE, ME)
- তার ভিতরে আরও ছোট = Teams
- সবচেয়ে ছোট = Individual employees। এক নজরে দেখা যায় কোন department সবচেয়ে বড় বা profitable।

সুবিধা: Space খুব efficiently ব্যবহার হয়। খুব বড় tree-ও এক screen-এ দেখা যায়। Netflix, Google Analytics-এ ব্যবহার হয়।



৭. Visualizing Complex Data and Relations

Complex Data মানে non-numerical data যেমন **text** এবং **social networks**।

Tag Cloud:

- User-generated tags visualize করার জন্য।
- **Importance of tag** দেখানো হয় **font size** এবং **color** দিয়ে।
- বড় font + dark color = সবচেয়ে popular tag।

উদাহরণ: একটা blog-এর tags — “Data Science” সবচেয়ে বড় font হলে বোঝা যায় এটা সবচেয়ে বেশি discussed।

Social Networks:

- Relationship visualize করা হয় (nodes = people, edges = friendship/follow)।
- Community detection, influencer খুঁজে বের করা যায়।

Heavy point: আজকালের data বেশিরভাগ non-numerical (text, graph, network)। এই techniques ছাড়া সেগুলো analyze করা যায় না।

Visualization Choice Guide (কোন Scenario-এ কোন Diagram)

Scenario / Data Type	সবচেয়ে ভালো Diagram	কেন ব্যবহার করবো? (Heavy Reason + Example)
Continuous Numerical Data (যেমন: marks, salary, height, weight)	Histogram	Distribution দেখাতে (কতটা ছড়ানো, skewed কি না, peak কোথায়)। Bars touch করে। Ex: ছাত্রদের exam marks-এর frequency distribution
Same continuous data কিন্তু শুধু summary চাই (min, Q1, median, Q3, max)	Boxplot	Five-number summary + outliers এক নজরে। কম space নেয়। Ex: দুটো class-এর marks তুলনা করতে
Histogram vs Boxplot	Histogram > Boxplot	একই five-number summary থাকলেও distribution আলাদা হতে পারে (normal vs bimodal) — histogram বলে দেয়
Categorical / Discrete Data (যেমন: department, blood group, gender)	Bar Chart	Group-এর মধ্যে comparison। Bars-এ gap থাকে। Ex: CSE vs EEE vs ME-এ ছাত্র সংখ্যা
Categorical data যেখানে proportion চাই (percentage ভাগ)	Pie Diagram	Whole = 360° , sector angle = frequency। Ex: Blood group distribution (A+, B+, O+)
Time series / Trend দেখাতে (দিন, মাস, বছর অনুসারে change)	Line Graph	Direction of change + trend (increase/decrease)। Ex: গত ১২ মাসের sales trend
Frequency distribution-এর smooth version	Frequency Curve	Histogram-এর points join করে smooth curve। Total area = total frequency। Ex: Marks-এর bell-shaped curve
দুটো variable-এর relationship (bivariate)	Scatter Plot	Clusters, outliers, positive/negative correlation দেখায়। Ex: Study hours vs Marks (positive), Price vs Demand (negative)
দুটো distribution তুলনা করতে (একই ধরনের কি না)	Q-Q Plot	Quantiles plot করে straight line হলে same distribution। Shift দেখায়। Ex: Branch 1 vs Branch 2 unit price

Correlation matrix / Feature relationship (ML-এ)	Heat Map	Color দিয়ে intensity দেখায় (dark = high value)। Ex: Confusion matrix বা correlation matrix
সব data point দেখাতে (nothing hidden)	Quantile Plot	প্রত্যেক x_i এর সাথে তার percentile। Overall behavior + unusual points। Ex: Income inequality দেখাতে
High-dimensional data (৫+ attributes)	Scatterplot Matrix	সব pairwise scatter plot একসাথে ($k \times k$ matrix)। Ex: Age, Income, Spending, Credit score
High-dimensional data (pattern খুঁজতে)	Parallel Coordinates	প্রত্যেক attribute একটা parallel axis, data = polygonal line। Ex: Customer-এর ৭টা feature একসাথে দেখা
Hierarchical / Tree-structured data (nested)	Tree-Map	Nested rectangles। Size = value, color = category। Ex: Company hierarchy (dept → team → employee)
Multi-parameter interactive exploration	Worlds-within-Worlds	Innermost world-এ main 2 params, outer world-এ বাকি params। Ex: Sales prediction model explore করতে
Text / User-generated tags	Tag Cloud	Font size + color = importance। Ex: Blog post-এর সবচেয়ে popular keywords
Social network / Relationship	Network Graph (স্লাইডে উল্লেখ)	Nodes = people, edges = connection। Ex: Facebook friend network

স্পেশাল টিপস (Exam-এ বারবার আসে)

- **Histogram vs Bar Chart** মনে রাখো:
 - Histogram → Continuous data + Bars touch + Distribution
 - Bar Chart → Categorical data + Gaps + Comparison
- **Boxplot** কখন যথেষ্ট নয়? → যখন full distribution shape জানতে চাও (তখন Histogram ব্যবহার করো)
- **Scatter Plot** দিয়ে correlation দেখা যায় কিন্তু **causation** প্রমাণ হয় না।
- **Heat Map** সবচেয়ে বেশি ব্যবহার হয় Machine Learning-এ correlation ও confusion matrix-এ।
- **High-dimension** হলে প্রথমে Parallel Coordinates বা Scatterplot Matrix চেষ্টা করো।

নিশ্চয়ই! তোমার সবগুলো পয়েন্টকে একটি পূর্ণাঙ্গ চার্টে সাজিয়ে দিচ্ছি। এই চার্টটি তোমাকে এক নজরে বুঝতে সাহায্য করবে কোন টুলটি কখন ব্যবহার করবে এবং তার সীমাবদ্ধতা কী।

ডাটা ভিজুয়ালাইজেশন টুলস সামারি চার্ট

ভিজুয়ালাইজেশন টুল	কী দেখা যায় / কী বের করা যায়	কোন ধরনের ডাটা	সীমাবদ্ধতা (Limitation)	বিকল্প সমাধান
Histogram	ডাটার ডিস্ট্রিবিউশন ও ফ্রিকোয়েন্সি।	Continuous (যেমন: উচ্চতা)	বিন সাইজ (Bin size) পরিবর্তন হলে প্যাটার্ন বদলে যায়।	Frequency Curve / Density Plot
Boxplot	৫-নাম্বার সামারি ও আউটলায়ার।	Numerical (এক বা একাধিক গ্রুপ)	ডাটার আসল ডিস্ট্রিবিউশন (Shape) বোঝা যায় না।	Violin Plot
Bar Chart	ক্যাটাগরি অনুযায়ী তুলনা।	Categorical (যেমন: দেশ, নাম)	অনেক বেশি ক্যাটাগরি হলে অগোছালো লাগে।	Treemap / Sorted Bar Chart
Pie Diagram	মোট অংশের কতটুকু কোন ভাগের (Proportion)।	Categorical (কম ভেরিয়েবল)	মানুষের চোখ কোণ (Angle) মেপে পার্থক্য বুঝতে ভুল করে।	Bar Chart
Line Graph	সময়ের সাথে পরিবর্তন (Trends)।	Time-series (সময় ভিত্তিক)	ডাটা পয়েন্ট খুব বেশি স্লাকচুয়েট করলে ট্রেন্ড বোঝা কঠিন।	Moving Average Line

Frequency Curve	ডাটার স্মুথ ডিস্ট্রিবিউশন।	Continuous	এটি র' ডাটা দেখায় না, শুধু আনুমানিক গড় দেখায়।	Histogram
Scatter Plot	দুটি ভেরিয়েবলের মধ্যে সম্পর্ক (Correlation)।	Numerical (X এবং Y)	অনেক বেশি ডাটা হলে বিন্দুগুলো জট পাকিয়ে যায় (Overplotting)।	Heatmap / Hexbin Plot
Q-Q Plot	আদর্শ ডিস্ট্রিবিউশনের সাথে তুলনা।	Numerical	এটি রিলেশন দেখায় না, শুধু ডিস্ট্রিবিউশন টাইপ দেখায়।	Histogram / KS Test
Heat Map	ডেনসিটি বা তীব্রতা (রেঙের মাধ্যমে)।	Matrix / Geographic	রেঙের পার্থক্য বোঝা কঠিন হতে পারে (Color blindness)।	Bubble Chart / Numeric Table
Quantile Plot	পার্সেন্টাইল ও ডাটার পজিশন।	Numerical (Sorted)	শুধু একটি ভেরিয়েবল নিয়ে কাজ করে।	Q-Q Plot
Scatterplot Matrix	সব ভেরিয়েবলের জোড়ায় জোড়ায় সম্পর্ক।	Multivariate (কম সংখ্যায়)	৫-৬টির বেশি অ্যাক্সিবিউট হলে গ্রাফ খুব ছোট হয়ে যায়।	Parallel Coordinates

Parallel Coordinates	হাই-ডাইমেনশনাল ডাটার প্যাটার্ন।	Multivariate (বেশি সংখ্যায়)	অনেক ডাটা হলে "Hairball" বা সুতার জট তৈরি হয়।	Dimensionality Reduction (PCA)
Tree-Map	হায়ারার্কি ও আয়তনের তুলনা।	Hierarchical (বড় সেট)	গভীরতা খুব বেশি হলে ভেতরের বক্সগুলো চেনা যায় না।	Sunburst Chart
Worlds-within-Worlds	হাই-ডাইমেনশনাল ফাংশনাল রিলেশন।	Multi-dimensional (3D+)	অত্যন্ত জটিল এবং সাধারণ মানুষের জন্য বোঝা কঠিন।	Interactive 3D Plots
Tag Cloud	টেক্সট ডাটার গুরুত্ব (ফন্ট সাইজে)।	Text Data	শব্দের প্রাসঙ্গিকতা (Context) বোঝা যায় না।	Word Network Graph
Network Graph	নোড ও লিঙ্কের মাধ্যমে সম্পর্ক।	Social/Relational Data	অনেক বেশি কানেকশন হলে ক্লাস্টার চেনা যায় না।	Matrix Plot