

Metric-Driven Evaluation: Accuracy, Precision & Recall

১. প্রথমে বুঝতে হবে — Classification কী?

Machine learning এ যখন আমরা কোনো model কে বলি "এটা spam নাকি not spam?" অথবা "এই patient এর cancer আছে কি নেই?" — এই ধরনের দুটো category তে ভাগ করার কাজকে বলে **Binary Classification**।

Model prediction করার পরে আমাদের জানতে হয় — model কতটা ভালো করল? এর জন্য দরকার **Evaluation Metrics**।

২. Confusion Matrix — সব কিছুর ভিত্তি—

True Positive (TP)
সঠিকভাবে **Positive** ধরা
আসলে Positive ✓ → Model বলল Positive ✓
উদাহরণ: Cancer আছে, model ও বলল আছে

False Negative (FN) — Type II Error
"The Miss" — মিস হয়ে গেছে
আসলে Positive ✓ → Model বলল Negative ✗
উদাহরণ: Cancer আছে, কিন্তু model বলল নেই 🙄

False Positive (FP) — Type I Error
"False Alarm" — ভুল alarm
আসলে Negative ✗ → Model বলল Positive ✓
উদাহরণ: Cancer নেই, কিন্তু model বলল আছে

True Negative (TN)
সঠিকভাবে **Negative** ধরা
আসলে Negative ✗ → Model বলল Negative ✗
উদাহরণ: Cancer নেই, model ও বলল নেই

Matrix Structure — চোখের সামনে রাখো

		Model এর Prediction	
		Positive বলেছে	Negative বলেছে
আসলে	Positive	TP ✓	FN ✗
	Negative	FP ✗	TN ✓

মনে রাখার trick: প্রথম শব্দ (True/False) = model ঠিক বলেছে কি না। দ্বিতীয় শব্দ (Positive/Negative) = model কী বলেছে।

৩. Accuracy — সামগ্রিক ঠিক-ভুলের হিসাব

Accuracy মানে হলো: মোট কতটা prediction সঠিক ছিল?

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

সহজ ভাষায়: সঠিক উত্তর ÷ মোট উত্তর

কিন্তু **Accuracy** কেন বিশ্বাসযোগ্য না সবসময়?

ধরো একটি hospital এ ১০০০ জন patient এর মধ্যে মাত্র ১০ জনের cancer আছে। যদি model সবাইকেই "cancer নেই" বলে দেয়:

- $TP = 0, TN = 990, FP = 0, FN = 10$
- $\text{Accuracy} = (0 + 990) \div 1000 = 99\%$ — দেখতে অসাধারণ!
- কিন্তু ১০ জন আসল রোগীকেই ধরতে পারেনি 😱

এই জন্যই শুধু Accuracy দিয়ে judge করা বিপজ্জনক। দরকার Precision ও Recall।

8. Precision — "যখন বলেছি Positive, কতবার সত্যি ছিল?"--- Dhorle Bipod, Charle Bipod

PRECISION	RECALL
প্রশ্ন: Model যখন Positive বলে, কতবার সত্যি?	প্রশ্ন: আসল Positive গুলোর কত % ধরা পড়েছে?
$TP \div (TP + FP)$	$TP \div (TP + FN)$
হর = যত জনকে Positive বলেছে লব = তার মধ্যে আসলেই Positive কতজন	হর = আসল Positive মোট কতজন লব = তার মধ্যে model কতজনকে ধরেছে
FP বাড়লে → Precision কমে	FN বাড়লে → Recall কমে

কোন situation এ কোনটা বেশি গুরুত্বপূর্ণ?	
High Precision চাই যখন — Spam filter: ভালো email কে spam বলা অনেক বড় সমস্যা। False alarm চাই না।	High Recall চাই যখন — Cancer detection: একজন রোগীকে মিস করলেও বিপদ। Miss চাই না।

৫. F1-Score — দুটোকে একসাথে মাপার উপায়

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$


এটা **Harmonic Mean** কেন? কারণ Arithmetic Mean কে ফাঁকি দেওয়া যায়। ধরো Precision = 1.0, Recall = 0.0:

- Arithmetic mean = $(1.0 + 0.0) \div 2 = 0.5$ — মনে হচ্ছে ঠিকঠাক!
- Harmonic mean = **0.0** — সত্যিটা বলে দিল!

F1 দুটোর মধ্যে যেটা কম সেটার দিকে বেশি টানে। তাই একটা ভালো হলেই কাজ হয় না, দুটোই reasonable হতে হবে।

৬. Slide এর Example — পুরো Math করি

Slide এ দেওয়া spam dataset থেকে পাওয়া গেছে: **TP = 3, FN = 2, FP = 1, TN = 4**—



৭. Precision-Recall Tradeoff — এই দুটো সবসময় টানাটানি করে

এটা বোঝা খুব জরুরি। Precision বাড়ালে Recall কমে, Recall বাড়ালে Precision কমে — কারণ:

- যদি model কে আরও "সতর্ক" করা হয় (শুধু ১০০% নিশ্চিত হলেই Positive বলবে) → Precision বাড়াবে কিন্তু অনেক Positive মিস হবে → Recall কমবে।
- যদি model কে আরও "উদার" করা হয় (সামান্য সন্দেহ হলেই Positive বলবে) → বেশি ধরবে কিন্তু ভুলও বেশি হবে → FP বাড়াবে → Precision কমবে।

এই balance এর জন্যই F1-Score ব্যবহার হয়।

৮. 🎯 Scenario-Based Practice Questions

এখানে directly TP, FN বলা নেই। তোমাকে situation পড়ে নিজে বুঝতে হবে।

🔥 Scenario 1 — Hospital Fraud Detection

একটি AI system তৈরি করা হয়েছে যেটা বলবে কোন insurance claim টা fraudulent (জালিয়াতি)। System টা ১০০০ টা claim review করল। এখানে **Positive = fraud**

- ৮০০ টা claim আসলেই সত্যিকারের, system ৭৮০ টাকে সঠিকভাবে "সত্যিকার" বলেছে।
- ২০০ টা claim আসলে fraud, system ১৪০ টাকে সঠিকভাবে "fraud" বলেছে।
- বাকি ৬০ টা fraud কে system "সত্যিকার" বলে ছেড়ে দিয়েছে।
- বাকি ২০ টা সত্যিকার claim কে system "fraud" বলেছে।

Step 1: TP, FN, FP, TN বের করো।

এখানে "Positive" = fraud (এটাই আমরা detect করতে চাই)।

	আসলে Fraud	আসলে সত্যিকার
System বলল Fraud	TP = 140	FP = 20
System বলল সত্যিকার	FN = 60	TN = 780

Step 2: Metrics বের করো।

$$\text{Precision} = \frac{140}{140 + 20} = \frac{140}{160} = 0.875 = 87.5\%$$

$$\text{Recall} = \frac{140}{140 + 60} = \frac{140}{200} = 0.70 = 70\%$$

$$F1 = 2 \times \frac{0.875 \times 0.70}{0.875 + 0.70} = 2 \times \frac{0.6125}{1.575} \approx 0.778$$

Step 3: Interpret করো।

Precision = 87.5% মানে system যখন বলে fraud, সেটা ৮৭.৫% সময়ই সত্যিকারের fraud। এটা ভালো — মানে false alarm কম।

Recall = 70% মানে ২০০ টা fraud এর মধ্যে ১৪০ টা মিস হয়ে গেছে। Fraud detection এ এটা কিন্তু বিপজ্জনক — কারণ ৬০ টা জালিয়াতি ধরা পড়ল না।

সিদ্ধান্ত: এই context এ Recall আরও বাড়ানো উচিত, কারণ fraud মিস হলে বেশি ক্ষতি।

🔥 Scenario 2 — Job Application Screening

একটি AI tool job application filter করছে। ৫০০ applicant এর মধ্যে ১০০ জন actually qualified।

- AI মোট ৮০ জনকে "qualified" বলেছে।

- এই ৮০ জনের মধ্যে ৬৪ জন সত্যিই qualified।
- বাকি ১৬ জন actually qualified না।

Step 1: TP, FP, FN, TN বের করো।

- TP = 64 (qualified ধরা পড়েছে)
- FP = 16 (unqualified কে qualified বলা হয়েছে)
- আসল qualified = 100, ধরা পড়েছে 64, তাই FN = 100 - 64 = **36**
- আসল unqualified = 400, FP = 16, তাই TN = 400 - 16 = **384**

Step 2: Metrics।

$$\text{Precision} = \frac{64}{64 + 16} = \frac{64}{80} = 0.80 = 80\%$$

$$\text{Recall} = \frac{64}{64 + 36} = \frac{64}{100} = 0.64 = 64\%$$

$$F1 = 2 \times \frac{0.80 \times 0.64}{0.80 + 0.64} = 2 \times \frac{0.512}{1.44} \approx 0.711$$

Interpretation:

Precision 80% — যাদের shortlist করেছে তাদের ৮০% সত্যিই ভালো candidate। এটা fair।

Recall 64% — কিন্তু ৩৬ জন qualified candidate কে বাদ দিয়ে দেওয়া হয়েছে। এটা মানে talented লোকজন মিস হয়ে যাচ্ছে।

এই situation এ দুটোই important। F1 = 0.71 মানে model মোটামুটি ঠিকঠাক কিন্তু আরও উন্নতি দরকার।

Scenario 3 — Slide এর Question (TN=400, TP=200, FP=150, FN=40)

এটা slide এ দেওয়া ছিল। সরাসরি values দেওয়া আছে, তাই practice করো:

$$\text{Precision} = \frac{200}{200 + 150} = \frac{200}{350} \approx 0.571 = 57.1\%$$

$$\text{Recall} = \frac{200}{200 + 40} = \frac{200}{240} \approx 0.833 = 83.3\%$$

$$F1 = 2 \times \frac{0.571 \times 0.833}{0.571 + 0.833} = 2 \times \frac{0.476}{1.404} \approx 0.678$$

Opinion on this model:

Recall খুব ভালো (83.3%) — আসল positive গুলোর বেশিরভাগ ধরা পড়েছে। কিন্তু Precision কম (57.1%) — কারণ FP = 150 অনেক বেশি। মানে model অনেক false alarm দিচ্ছে।

এই model টা এমন কাজে ভালো যেখানে মিস করা বিপজ্জনক (যেমন disease screening) — কিন্তু যেখানে false alarm cost বেশি (যেমন spam filter) সেখানে এটা ভালো না।

৯. 🧠 Quick Reference চিটশিট---

Metric	Formula	প্রশ্ন যেটার উত্তর দেয়	কমে যায় যখন
Accuracy	$(TP+TN)/(TP+TN+FP+FN)$	মোট কত % ঠিক?	FP বা FN বাড়লে
Precision	$TP/(TP+FP)$	Positive বললে কতবার সত্যি?	FP বাড়লে ↓
Recall	$TP/(TP+FN)$	আসল Positive কত % ধরা পড়েছে?	FN বাড়লে ↓
F1-Score	$2 \times (P \times R) / (P + R)$	দুটোর balance কেমন?	P বা R যেকোনো একটা কমলে ↓

FP = "False Alarm"
Precision কে hurt করে

FN = "The Miss"
Recall কে hurt করে