



Foundations of Predictive Modeling

Feature Engineering, Supervised Learning, Overfitting, Bias-Variance

5. Supervised Learning — শেখানো থেকে শেখা

মূল ধারণা

Supervised Learning মানে হলো — তুমি model কে উদাহরণ দিয়ে শেখাও।

প্রতিটা উদাহরণে থাকে:

- **X** = Input (features) — যা দিয়ে predict করবে
- **y** = Label (সঠিক উত্তর) — যা predict করতে হবে

Model শেখে এই $X \rightarrow y$ এর সম্পর্কটা।

Real life example: তুমি একটা বাচ্চাকে হাজারটা ছবি দেখালে — "এটা বিড়াল, এটা কুকুর, এটা বিড়াল..."
বাচ্চা pattern শিখে নেয়। Supervised Learning ঠিক এভাবেই কাজ করে।

দুই ধরনের **Supervised Learning**:

Regression — সংখ্যা predict করা

Definition: Output যখন **continuous** (যেকোনো সংখ্যা হতে পারে)

উদাহরণ:

- বাড়ির দাম কত হবে? $\rightarrow$ 50 লাখ, 80 লাখ, 1.2 কোটি
- আগামীকাল তাপমাত্রা কত? $\rightarrow 32.5^{\circ}\text{C}$
- একজন মানুষের বয়স কত? $\rightarrow 27.3$ বছর

Goal: Predicted value আর Actual value এর পার্থক্য (error) যতটা সম্ভব কমানো।

এই error কে বলে **Squared Residuals** — প্রতিটা ভুলকে বর্গ করে যোগ করা হয় (বড় ভুলকে বেশি শাস্তি দেওয়ার জন্য)।

Actual: 50 লাখ

Predicted: 47 লাখ

Residual = $50 - 47 = 3$ লাখ

Squared Residual = 9 লাখ^২

Classification — শ্রেণী বলা

Definition: Output যখন **discrete** (নির্দিষ্ট কয়েকটা category)

উদাহরণ:

- এই email কি Spam নাকি Not Spam? → দুটো class
- এই ছবিতে কি বিড়াল, কুকুর, নাকি পাখি? → তিনটা class
- এই transaction কি fraud নাকি না? → দুটো class

Goal: দুটো (বা বেশি) class এর মাঝে সর্বোত্তম **boundary** তৈরি করা — যাতে নতুন data দেখলেই বলতে পারে কোন class এ পড়ে।

Regression: "এই বাড়ির দাম 73.5 লাখ টাকা"

Classification: "এই বাড়িটা high-value নাকি low-value category তে পড়ে"

২. Feature Engineering — Raw Data কে কাজের করা

সমস্যাটা কী?

ধরো তোমার কাছে দুটো feature আছে:

- বয়স: 25, 30, 45 (ছোট সংখ্যা)
- বেতন: 30,000, 75,000, 120,000 (বড় সংখ্যা)

Model যদি এই দুটো distance হিসাব করে শেখে, তাহলে বেতন সবসময় জিতবে — কারণ সংখ্যাটা বড়।

বয়সের পার্থক্য ৫ বছর vs বেতনের পার্থক্য ৫০,০০০ টাকা — model এর কাছে বেতনটাই বেশি "গুরুত্বপূর্ণ" মনে হবে, কিন্তু সেটা সত্যি নাও হতে পারে।

Feature Scaling এই সমস্যা সমাধান করে।

পদ্ধতি ১: Normalization (Min-Max Scaling)

$$X_{\text{norm}} = (X - X_{\text{min}}) / (X_{\text{max}} - X_{\text{min}})$$

কী করে: সব value কে 0 থেকে 1 এর মধ্যে নিয়ে আসে।

উদাহরণ: বয়স: [20, 30, 40, 50]

- $X_{\text{min}} = 20$, $X_{\text{max}} = 50$

- $20 \rightarrow (20-20)/(50-20) = 0.0$
- $30 \rightarrow (30-20)/(50-20) = 0.33$
- $40 \rightarrow (40-20)/(50-20) = 0.67$
- $50 \rightarrow (50-20)/(50-20) = 1.0$

কখন ব্যবহার করবে: যখন data এর range জানা থাকে এবং outlier কম থাকে।

পদ্ধতি ২: Standardization (Z-Score)

$$X_{\text{std}} = (X - \mu) / \sigma$$

যেখানে μ = mean (গড়), σ = standard deviation

কী করে: Data কে এমনভাবে সাজায় যাতে **Mean = 0, Variance = 1** হয়।

উদাহরণ: বয়স: [20, 30, 40, 50], Mean = 35, SD = 11.18

- $20 \rightarrow (20-35)/11.18 = -1.34$
- $35 \rightarrow (35-35)/11.18 = 0.0$
- $50 \rightarrow (50-35)/11.18 = +1.34$

Zero এর নিচে = গড়ের নিচে, Zero এর উপরে = গড়ের উপরে।

কখন ব্যবহার করবে:

- **Linear Regression** — Gaussian distribution assume করে
 - **SVM** — distance-based, তাই scale matter করে
 - Outlier থাকলে Normalization এর চেয়ে ভালো কাজ করে
-

৩. Model Fit — Model কি ঠিকমতো শিখছে?

তিনটা অবস্থা হতে পারে:



Underfitting — অনেক কম শেখা

Model এত সরল যে সে আসল pattern ধরতেই পারেনি।

- **Training error:** বেশি (নিজের data তেও ভুল করছে)
- **Test error:** বেশি
- কারণ: Model অনেক সরল, **High Bias**

উদাহরণ: তুমি একটা curved line fit করতে চাইছ, কিন্তু model শুধু straight line আঁকছে।

Real data: U shaped curve
Model: _____ flat line

😞 Overfitting — অনেক বেশি মুখস্থ করা

Model training data এতটাই মুখস্থ করেছে যে নতুন data দেখলে আর কাজ করে না।

- **Training error:** খুব কম (training data তে প্রায় perfect)
- **Test error:** অনেক বেশি (নতুন data তে মুখ খুঁড়ে পড়ে)
- কারণ: Model অনেক জটিল, **High Variance**

উদাহরণ: পরীক্ষার আগে শুধু গতবারের প্রশ্ন মুখস্থ করলে। একই প্রশ্ন আসলে full marks, কিন্তু একটু ঘুরিয়ে দিলে শূন্য।

Training data: model perfectly fits every point সহ noise
New data: model completely confused

😊 Good Fit — সঠিক Balance

- Training error: মোটামুটি কম
- Test error: মোটামুটি কম
- দুটোর মধ্যে বেশি পার্থক্য নেই

অবস্থা	Training Error	Test Error	কারণ
Underfitting	বেশি	বেশি	অনেক সরল, High Bias
Good Fit	কম	কম	সঠিক complexity
Overfitting	অনেক কম	বেশি	অনেক জটিল, High Variance

8. Bias-Variance Tradeoff — সবচেয়ে গুরুত্বপূর্ণ Concept

Bias কী?

Definition: Model এর ভুল assumptions থেকে আসা error।

সহজ ভাষায়: Model আগে থেকেই ধরে নিয়েছে data একটা নির্দিষ্ট shape এ থাকবে — কিন্তু আসলে সেটা না।

High Bias model **systematically** ভুল করে — সবসময় একদিকে ঝুঁকে থাকে।

উদাহরণ: তীরন্দাজ যে সবসময় বাম দিকে মারে — accurate না, consistent।

Variance কী?

Definition: Training data এর ছোট পরিবর্তনের প্রতি model এর অতিরিক্ত সংবেদনশীলতা।

সহজ ভাষায়: Training data একটু বদলালেই model সম্পূর্ণ বদলে যায়।

High Variance model training data এর **noise** ও শিখে ফেলে।

উদাহরণ: তীরন্দাজ যে কখনো বাম, কখনো ডান, কখনো উপর — সব জায়গায় মারে — consistent না।

The Fundamental Equation

Total Error = Bias² + Variance + Irreducible Error (σ^2)

Irreducible Error (σ^2):

Data এর মধ্যেই যে noise আছে, সেটা কোনো model দিয়েই কমানো যাবে না। এটা সমস্যার নিজস্ব অনিশ্চয়তা।

উদাহরণ: আগামীকাল বৃষ্টি হবে কি না — এই prediction এ সবসময় কিছু uncertainty থাকবেই।

Tradeoff কীভাবে কাজ করে?

Model Complexity বাড়ালে:

Bias ↓ (model বেশি flexible, কম assumption)

Variance ↑ (model noise ও শিখতে শুরু করে)


Model Complexity কমালে:

Bias ↑ (model অনেক সরল, pattern ধরতে পারে না)

Variance ↓ (model stable, কিন্তু inaccurate)

Graphically:

Error



লক্ষ্য: এই **Sweet Spot** খুঁজে বের করা — যেখানে Total Error সবচেয়ে কম।

দুটো **Error** এর তুলনা — একটা **Table**

	High Bias	High Variance
অন্য নাম	Underfitting	Overfitting
Training Error	বেশি	কম
Test Error	বেশি	অনেক বেশি
Model	অনেক সরল	অনেক জটিল
সমাধান	জটিল model ব্যবহার করো	Data বাড়াও / Regularization

 সব **Concept** এক জায়গায়

Raw Data



Feature Engineering (Normalization / Standardization)



Supervised Learning (Regression / Classification)



Model Train করো



Model কেমন fit করেছে?

- Underfitting? → Bias বেশি → Model জটিল করো
 - Overfitting? → Variance বেশি → Data বাড়াও / সরল করো
 - Good Fit?  → Bias-Variance Balance হয়েছে!
-